1 ER-DRO model (with CVaR-type ambiguity set)

데이터: (y^s, x^s), $s \in S$ — 예를 들어 도시·연도별 관측 선택확률 y^s와 도시 특성 x^s. 관측 하나가 시나리오 하나이므로 S는 관측 번호의 집합이다. 회귀로 $\hat{f}$와 잔차 $\hat{\varepsilon}^s = y^s - \hat{f}(x^s)$를 얻고(4.A), 후보 도시 c의 특성 x_c로 시나리오 D_c^s를 만든다(4.B).

$$\min_{y,\,q,\,O,\,U,\,\tau,\,w} \quad \underbrace{\sum_c F_c y_c}_{\text{Entry costs}} + \underbrace{\sum_c K_c q_c}_{\text{Vehicle costs}} + \tau + \underbrace{\frac{1}{|S|(1-\zeta)} \sum_{s\in S} w^s}_{\text{CVaR of scenario penalties}}$$

※ baseline의 $\frac{1}{|S|}\sum_s H(q, D^s)$ 자리가 $\tau + \frac{1}{|S|(1-\zeta)}\sum_s w^s$로 바뀐 것, where $H(q, D^s) = c_c^+ O_c^s + c_c^- U_c^s$. 컨텍스트 x_c는 시나리오 값 $D_c^s = M_c\, p_c^s$에만 들어가고 최적화 구조는 그대로.

2 Constraints

$$\begin{aligned}
w^s \;\geq\; & \sum_c \left(c_c^+ O_c^s + c_c^- U_c^s\right) - \tau && \forall s \in S, \\
& \kappa_c q_c - D_c^s = O_c^s - U_c^s && \forall c \in C,\ s \in S, \\
& 0 \leq q_c \leq \bar{q}_c\, y_c && \forall c \in C, \\
& \textstyle\sum_{c\in C} q_c \leq Q, && \\
& y_c \in \{0,1\}, \quad q_c \in \mathbb{Z}_{\geq 0} && \forall c \in C, \\
& O_c^s,\ U_c^s \geq 0 && \forall c \in C,\ s \in S, \\
w^s \geq 0 \quad \forall s \in S, \qquad & \tau \in \mathbb{R}. &&
\end{aligned}$$

Constraint	Meaning
$0 \leq q_c \leq \bar{q}_c y_c$	Zero vehicles if the city is not entered; up to the city-specific limit if it is entered
$\sum_c q_c \leq Q$	Total vehicle limit
$\kappa_c q_c - D_c^s = O_c^s - U_c^s$	The difference between service capacity and robotaxi demand equals unused capacity minus unmet demand.
$w^s \geq \sum_c (c_c^+ O_c^s + c_c^- U_c^s) - \tau,\ w^s \geq 0$	시나리오 s의 벌금이 문턱 τ를 넘은 양. 최적화가 w^s를 가장 작게 잡으므로 $w^s = (\text{벌금}^s - \tau)^+$가 된다.

3 Notation

3.1 textbfContextual + DRO에서 추가되는 기호

Symbol	Meaning	Type and unit
(y^s, x^s)	관측 s의 종속변수(선택확률)와 공변량	Data; $s \in S$
x_c	후보 도시 c의 특성(공변량) 벡터	Input; Kannan의 새 관측 x에 해당
$\hat{f}$	회귀함수 추정치 $\hat{f}(x) \approx \mathbb{E}[y \mid x]$	Estimated function
$\hat{\varepsilon}^s$	잔차 $y^s - \hat{f}(x^s)$	Derived; p 척도
ζ	CVaR형 모호집합의 반경(꼬리 비율). $1-\zeta$ = 최악 그룹으로 남기는 시나리오 비율	Input; $[0, 1)$
τ	벌금 문턱. 결정변수이며 최적해에서 "$|S|(1-\zeta)$번째로 큰 벌금"	Decision variable; currency
w^s	시나리오 s의 벌금이 τ를 넘은 양	Decision variable; currency

3.2 Baseline 기호

Symbol	Meaning	Type and unit
C	Set of potential candidate cities	Input set; cities
S	Set of demand scenarios	Input set; scenarios. 여기서는 회귀 데이터 관측 번호의 집합, $\|S\| =$ 관측치 수
y_c	1 if city c is entered, else 0	Decision variable; binary (0 or 1)
q_c	Number of vehicles deployed in city c	Decision variable; vehicles (integer)
κ_c	Number of trips one vehicle can serve during the period	Scale parameter; trips/vehicle over the evaluation period
Q	Total number of vehicles available for deployment	Input parameter; vehicles
$\bar{q}_c$	Upper bound on vehicle deployment in each city	Input parameter; vehicles
F_c	Fixed cost of city entry and basic infrastructure	Input parameter; currency over the evaluation period
K_c	Per-vehicle preparation, deployment, and holding cost over the evaluation period	Input parameter; currency/vehicle over the evaluation period
c_c^+	Additional loss per unit of unused service capacity	Input parameter; currency/trip of unused capacity
c_c^-	Foregone contribution margin per unit of unserved potential demand	Input parameter; currency/unserved trip
M_c	Total number of **potential travel opportunities across all modes** in city c during one year	Input parameter; usage opportunities over the evaluation period. data or assumption
p_c^s	Probability of choosing robotaxi service for a travel opportunity in city c	Derived input (회귀에서 생성); dimensionless probability in $[0,1]$. $p_c^s = \mathrm{proj}_{[0,1]}(\hat{f}(x_c) + \hat{\varepsilon}^s)$
D_c^s	Robotaxi choice demand	Derived input; trips over the evaluation period. $D_c^s = M_c p_c^s$
O_c^s	Unused service capacity	Outcome variable; trips over the evaluation period. $O_c^s = (\kappa_c q_c - D_c^s)^+$
U_c^s	Unserved robotaxi demand	Outcome variable; trips over the evaluation period. $U_c^s = (D_c^s - \kappa_c q_c)^+$

4 Explanations

4.1 contextual demand를 반영한 CVaR 방식의 식 전개

A. 정의.

- $H(q, D^s)$: 시나리오 s의 2단계 비용(문서 맨 위 Common second stage).

$$H(q, D^s) = \min_{O^s, U^s \geq 0} \sum_c \left(c_c^+ O_c^s + c_c^- U_c^s\right) \quad \text{s.t.} \quad \kappa_c q_c - D_c^s = O_c^s - U_c^s \ \ \forall c,$$

  최적해에서 $O_c^s = (\kappa_c q_c - D_c^s)^+$, $U_c^s = (D_c^s - \kappa_c q_c)^+$ 이므로 $H(q, D^s) = \sum_c \left[c_c^+ (\kappa_c q_c - D_c^s)^+ + c_c^- (D_c^s - \kappa_c q_c)^+\right]$.

- w^s: 시나리오 s의 벌금이 문턱 τ를 넘은 양. 최적해에서 $w^s = \left(H(q, D^s) - \tau\right)^+$.

- $D_c^s(x_c) = D_c^s = M_c\, p_c^s = M_c\ \mathrm{proj}_{[0,1]}\left(\hat{f}(x_c) + \hat{\varepsilon}^s\right), \qquad D^s = \left(D_1^s,\, D_2^s,\, \ldots,\, D_{|C|}^s\right)$

- $\hat{P}_n^{\mathrm{ER}}(x) = \frac{1}{|S|} \sum_{s \in S} \delta_{D^s(x)}, \qquad \hat{\mathcal{P}}_n(x) = \left\{ \sum_s p_s \delta_{D^s(x)} : \ p \in \mathfrak{P}_n(x; \zeta) \right\}$

B. 사슬. Kannan의 논문으로부터 정의된 Residuals-based DRO formulation $\min_{z \in \mathbb{Z}} \left[\sup_{Q \in \hat{\mathcal{P}}_n(x)} \mathbb{E}_{Y \sim Q}[c(z, Y)] \right]$ 에서 결정 $z = (y, q)$를 고정하고 내부 sup부터 전개한다.

$$
\begin{aligned}
\sup_{Q\in\hat{\mathcal{P}}_n(x)} \mathbb{E}_{Y\sim Q}[c(z,Y)] &\overset{(a)}{=} \sup_{p\in\mathfrak{P}_n(x;\zeta)} \sum_{s\in S} p_s\, c(z, D^s(x)) \\
&\overset{(b)}{=} \sum_c F_c y_c + \sum_c K_c q_c + \sup_{p\in\mathfrak{P}_n} \sum_{s\in S} p_s\, H(q, D^s) \\
&\overset{(c)}{=} \sum_c F_c y_c + \sum_c K_c q_c + \min_{\tau\in\mathbb{R}} \Big[\tau + \frac{1}{|S|(1-\zeta)} \sum_{s\in S} \big(H(q,D^s) - \tau\big)^+\Big] \\
&\overset{(d)}{=} \sum_c F_c y_c + \sum_c K_c q_c + \min_{\tau,\,w} \Big\{\tau + \frac{1}{|S|(1-\zeta)} \sum_{s\in S} w^s \;:\; w^s \ge H(q,D^s) - \tau,\; w^s \ge 0 \;\forall s\Big\} \\
&\overset{(e)}{=} \sum_c F_c y_c + \sum_c K_c q_c + \min_{\tau,\,w,\,O,\,U} \Big\{\tau + \frac{1}{|S|(1-\zeta)} \sum_{s\in S} w^s \;:\; w^s \ge \sum_c \big(c_c^+ O_c^s + c_c^- U_c^s\big) - \tau, \\
&\qquad\qquad \kappa_c q_c - D_c^s = O_c^s - U_c^s,\;\; w^s, O_c^s, U_c^s \ge 0 \;\forall c, s\Big\}.
\end{aligned}
$$

마지막으로 바깥의 $\min_{y,q}$를 씌우면 $\min_{y,q}\min_{\tau,w,O,U} = \min_{y,q,O,U,\tau,w}$로 합쳐져

$$
\begin{aligned}
\text{(f)}\quad \min_{y,\,q,\,O,\,U,\,\tau,\,w}\; & \sum_c F_c y_c + \sum_c K_c q_c + \tau + \frac{1}{|S|(1-\zeta)} \sum_{s\in S} w^s \\
\text{s.t. } & w^s \ge \sum_c \big(c_c^+ O_c^s + c_c^- U_c^s\big) - \tau, \quad w^s \ge 0 \qquad \forall s\in S, \\
& \kappa_c q_c - D_c^s = O_c^s - U_c^s, \quad O_c^s, U_c^s \ge 0 \qquad \forall c\in C,\; s\in S, \\
& 0 \le q_c \le \bar{q}_c y_c, \quad \textstyle\sum_c q_c \le Q, \quad y_c \in \{0,1\},\; q_c \in \mathbb{Z}_{\ge 0},\; \tau\in\mathbb{R},
\end{aligned}
$$

C. 각 등호가 성립하는 이유.

- (a) 같은 지지집합형이므로 $Q = \sum_s p_s \delta_{D^s}$ 이고 기대값은 가중합.
- (b) $c(z, D^s) = \sum_c F_c y_c + \sum_c K_c q_c + H(q, D^s)$에서 앞의 두 항은 s와 무관하고 $\sum_s p_s = 1$이므로 sup 밖으로 나온다.
- (c) $\mathfrak{P}_n$이 Example 1의 상자($p_s \le \frac{1}{|S|(1-\zeta)}$)이면 sup은 벌금이 큰 $|S|(1-\zeta)$개의 평균, 즉 CVaR_ζ이고, 이것은 Rockafellar–Uryasev의 문턱 표현과 같다.
- (d) $(\cdot)^+$의 선형화. $w^s \ge H - \tau$, $w^s \ge 0$ 아래에서 w^s를 최소화하면 $w^s = (H-\tau)^+$가 되므로 값이 같다.
- (e) $H(q, D^s)$ 자체가 O^s, U^s에 대한 min이다. "$w^s \ge \min_{O,U}(\cdots) - \tau$"는 "어떤 실행가능한 O^s, U^s에 대해 $w^s \ge (\cdots) - \tau$"와 같으므로, 내부 min을 바깥 min에 합치고 균형식을 제약으로 올릴 수 있다.
- (f) 바깥 $\min_{y,q}$와 내부 $\min_{\tau,w,O,U}$는 모두 최소화라 하나로 합쳐진다. sup은 (c)에서 이미 min으로 바뀌었으므로 min–max 구조가 남지 않는다.

4.2 시나리오 생성

A. 회귀

후보 도시 c의 특성 x_c에 대해

$$
p_c^s = \mathrm{proj}_{[0,1]}\big(\hat{f}(x_c) + \hat{\varepsilon}^s\big), \qquad D_c^s = M_c\, p_c^s, \qquad s\in S
$$

$\hat{f}$를 적합하고 잔차 $\hat{\varepsilon}^s = y^s - \hat{f}(x^s)$, $s\in S$. x^s는 training points고 x와 ϵ은 N(0,1)을 따르고 공변량 x와 독립이라 가정한다 (회귀 후 등분산성 확인 필요)., 또 baseline model처럼 M_c는 고정으로 둔다.

B. 공변량 X는 무엇인가?

- **B-1. 어떻게 M을 정하는가:** 세부 내용은 *2.driving factors/C.Selection/Factors_of_M*를 참고한다.

M_c를 **NHTS의 인구집단별 1인당 통행률 × 도시별 인구**로 구성한다. 이 방법으로 하면 회귀 없이 모든 후보 도시에 같은 정의로 계산하는 고정값이 산출된다.

- **B-2. 어떻게 p를 정하는가:**

세부 내용은 *2.driving factors/C.Selection/Factors_of_p*를 참고한다.

1차 선택 결과, 도시 특성 2개와 결정의존 서비스 변수 3개를 우선 대상으로 정리한다. 왜생 변수 2개를 먼저 현 모델에서 테스트해보고, 내생 서비스 변수의 사용은 decision-dependent ER-DRO 확장에서 반영한다. 외생、내생 구분은 운영 결정에 의존하는지에 따른 구분이다.

- 외생 : **무차량 가구 비율 (외생)** **연령 구조 (외생)**
- 내생 : **상대 요금 (내생)** **상대 대기시간 (내생)** **차내 지원기능 (내생)**

C. 회귀는 어떠한 방식으로 할 것인가, 그리고 왜? : 아직 결정해야 함

※ Kannan et al. (Residuals-based Distributionally Robust Optimization)

회귀는 아무 방식이나 되나 — 논문 틀은 방법을 가리지 않습니다(OLS, Lasso, Ridge, kNN, 랜덤포레스트 모두 가능). 다만 세 가지를 고려해야 합니다.

- **이론 조건.** 가정 2·8·15는 회귀오차가 $|S|$에 따라 얼마나 빨리 줄어드는지에 대한 것입니다. OLS·Lasso 같은 모수적 방법은 $r = 1$(오차 $\sim |S|^{-1/2}$)을 만족하고, 비모수적 방법은 $r = O(1)/d_x$로 느립니다. 도시 수가 적고 특성 수가 많으면 모수적 방법이어야 이론이 붙습니다.
- **소표본이면 정규화.** 논문 실험에서 $|S|$가 d_x에 비해 작을 때 Lasso·Ridge가 OLS보다 좋았고, DRO와 상보적이었습니다. 또 $|S|$가 작으면 학습 잔차가 낙관적으로 작아지므로 이전 논문 [34]의 leave-one-out(jackknife) 잔차를 쓰는 것이 낫습니다.
- **모델 구조 가정.** $Y = f^*(X) + \varepsilon$에서 오차가 X와 독립(동분산)이어야 잔차를 도시 간에 공유할 수 있습니다. 회귀 대상을 통행 수 D로 하면 큰 도시의 오차가 더 크기 마련이라 이 가정이 깨집니다. 선택확률 p(또는 logit p)를 도시 특성에 회귀하고 $D_c = M_c p_c$로 만들면 동분산에 훨씬 가깝고, 사영 $[0,1]$도 자연스럽습니다. 그래도 이분산이 남으면 저자들의 후속 논문 [35]의 확장을 씁니다.

D. Ambiguity set 정하기

We use the CVaR-based ambiguity sets with the same support as $\hat{P}_n^{ER}$, the empirical distribution of the residuals.

※ Kannan et al. (Residuals-based Distributionally Robust Optimization)

Ambiguity sets with the same support as $\hat{P}_n^{\mathrm{ER}}(x)$ (cf. [4, 6], for instance): given radius $\zeta_n(x) \geq 0$, set

$$\hat{\mathcal{P}}_n(x) = \Big\{ Q = \sum_{i=1}^{n} p_i \, \delta_{\mathrm{proj}_{\mathcal{Y}}(\hat{f}_n(x)+\hat{\varepsilon}_n^{\,i})} \;:\; p \in \mathfrak{P}_n\big(x; \zeta_n(x)\big) \Big\},$$

where $\mathfrak{P}_n(x; \zeta_n(x))$ is a generic ambiguity set for the n-dimensional vector of probabilities p. We focus on sets $\mathfrak{P}_n(x; \zeta_n(x))$ that satisfy for each $x \in \mathcal{X}$

$$\begin{aligned} p \in \mathbb{R}^n_+ \;\text{ and }\; \sum_{i=1}^{n} p_i = 1, \quad \forall p \in \mathfrak{P}_n\big(x; \zeta_n(x)\big), \\ \lim_{\zeta \downarrow 0} \mathfrak{P}_n(x; \zeta) = \mathfrak{P}_n(x; 0) = \Big\{ \Big(\tfrac{1}{n}, \tfrac{1}{n}, \ldots, \tfrac{1}{n}\Big) \Big\}. \end{aligned} \tag{8}$$

Example 1. CVaR-based ambiguity set [45, 48]: given radius $\zeta_n(x) \in [0, 1)$, set

$$\mathfrak{P}_n\big(x; \zeta_n(x)\big) := \Big\{ p \in \mathbb{R}^n_+ \;:\; \sum_{i=1}^{n} p_i = 1, \;\; p_i \leq \frac{1}{n\big(1 - \zeta_n(x)\big)}, \;\; \forall i \in [n] \Big\}.$$

Observe that $\zeta_n(x)$ enters the ambiguity set $\mathfrak{P}_n(x; \zeta_n(x))$ through the CVaR risk parameter.

D-1. 왜 CVaR을 택했는가?

시나리오 $|S|$개에 확률 $1/|S|$씩 준 것을 그대로 믿지 않는다면 두 가지를 의심할 수 있다. 시나리오 **값**을 의심하면 점을 움직이는 집합(Wasserstein, SRO)이고, 시나리오 **확률**을 의심하면 가중치만 바꾸는 집합(CVaR형)이다. 우리는 후자를 택한다.

- **구조가 그대로 유지된다.** "벌금이 큰 $(1-\zeta)$ 비율의 시나리오 평균"은 문턱 τ와 초과분 w^s만 더하면 기존 MILP에 그대로 얹힌다. 점을 움직이는 집합은 정수 결정 안에 min–max–min이 생겨 논문도 일반적으로 어렵다고 본다.
- **점을 움직이는 집합은 c^+/c^- 비율에 따라 뜻이 달라진다.** $c^+ \ll c^-$이면 최악 분포는 수요를 위로만 밀어 수요 배율 민감도와 사실상 같은 실험이 되고, c^+가 c^-에 가까워지면 유휴 쪽으로도 밀어 해석이 복잡해진다. CVaR형은 비율과 무관하게 "나쁜 시나리오가 더 자주 온다면"이라는 같은 질문을 던지므로, 비율 조합을 바꿔 가며 비교하기에 더 깔끔하다.
- **가장 근거 없는 것은 값이 아니라 빈도다.** ER-DRO의 시나리오 값은 회귀 예측 + 실제 잔차라 데이터에 근거하지만, 관측이 적을수록 "각 시나리오가 똑같이 $1/|S|$"라는 가정이 가장 취약하다. 확률만 흔드는 집합이 그 약점을 겨냥한다.
- **설명이 쉽다.** $\zeta = 0.5$는 "최악 절반의 평균을 최소화"이고, 결과는 "한 대의 가치" 논리에서 시나리오 비율을 최악 가중치로 바꾼 것으로 읽힌다.

단서: 논문 실험에서는 같은 부류인 Hellinger형이 Wasserstein보다 개선 폭이 작았다. 연속분포의 소표본 상황이라 우리와 다르지만 검증은 필요하므로, 두 집합을 모두 돌려 비교표를 둔다.

D-2. "τ 요령"의 이해

※ Example (아래 숫자는 공변량 없는 v3 인스턴스, 즉 손으로 설계한 시나리오 10개에서의 예시)

기준 배치 $(132, 368, 500)$을 고정하고 $\zeta = 0.5$(최악 5개)로 놓으면, 시나리오별 벌금 $C^s = \sum_c c_c^- U_c^s$와 풀이기가 찾는 τ, w^s는 다음과 같습니다(M USD).

s	8	4	5	6	10	9	1	3	2	7
C^s	297.7	288.0	220.6	174.4	156.5	114.7	104.0	58.8	56.9	6.3
$w^s = (C^s - \tau)^+$	141.2	131.5	64.1	17.9	0	0	0	0	0	0

$\tau = 156.5$(5번째로 큰 벌금)이고, 목적함수는 $18.47 + 156.5 + \frac{1}{5}(141.2 + 131.5 + 64.1 + 17.9) = 245.9$. 이것이 정확히 고정비 + 최악 5개 평균 227.4입니다. 즉 w^s는 "시나리오 s의 벌금이 문턱을 넘은 양"이고, 최악 그룹에 안 드는 시나리오는 0입니다. 배치가 바뀌면 C^s가 바뀌고 τ, w^s도 따라 바뀝니다.

τ는 내가 정하는 게 아닙니다. τ는 y, q와 같은 결정변수라 풀이기가 찾습니다. 최적해에서는 항상 "$|S|(1-\zeta)$번째로 큰 벌금"이 됩니다. 내가 정하는 것은 ζ 하나뿐입니다(4.D의 세 가지 방법 중 하나로).

※ 참조논문

- Rockafellar & Uryasev (2000), "Optimization of conditional value-at-risk", *Journal of Risk*. τ 요령의 원조입니다. 거기서는 문턱을 α, 꼬리 수준을 β로 씁니다(우리 τ, ζ).
- Shapiro, Dentcheva, Ruszczyński, *Lectures on Stochastic Programming*, 위험회피 최적화 장. CVaR의 두 표현, 즉 "$\min_\tau$ 문턱 표현"과 "확률을 $\frac{1}{|S|(1-\zeta)}$까지만 키울 수 있는 최악 가중치 표현"이 같다는 것이 여기 있습니다. 논문 Example 1의 집합은 후자를 그대로 쓴 것입니다.
- Kannan 논문 자체 7절: 포트폴리오 목적함수를 $\min_\tau \mathbb{E}[\tau + \frac{1}{1-\beta}\max\{0, \cdot - \tau\}]$로 쓰고 LP로 풀었습니다. 우리와 같은 방식입니다.

E. ζ (반경)를 정하는 방법

CVaR형에서 ζ는 거리 반경이 아니라 "최악 시나리오를 몇 개까지 볼 것인가"를 정하는 꼬리 비율입니다($1-\zeta$ = 남기는 비율).

E-1. Cross validation

E-2. 의사결정자(연구자)가 원하는 위험 회피 성향(Risk Preference) 수준에 따라 ζ 값을 직관적으로 사전 설정하는 방식

※ Kannan et al. (Residuals-based Distributionally Robust Optimization)

Algorithm 2 Specifying a covariate-independent radius ζ_n using the ER-DRO problem

Input: data $\mathcal{D}_n$, set of candidate radii Δ, number of folds K, and number of covariate realizations sampled during each fold $T \leq \lfloor \frac{n}{K} \rfloor$.
Partition $[n]$ into subsets $S_1, \ldots, S_K$ of (roughly) equal size at random. Let $\mathcal{D}_{-k} := \mathcal{D}_n \setminus \{(y^i, x^i)\}_{i \in S_k}$.
for $k = 1, \ldots, K$ **do**
  Pick without replacement a random subset $\bar{\mathcal{X}}$ of $\{x^i\}_{i \in S_k}$ of size T.
  for $\bar{x} \in \bar{\mathcal{X}}$ **do**
    for $\zeta \in \Delta$ **do**
      Fit a regression model $\hat{f}_{-k}$ using the data $\mathcal{D}_{-k}$ and compute its in-sample residuals $\{\hat{\varepsilon}^i_{-k}\}_{i \notin S_k} := \{y^i - \hat{f}_{-k}(x^i)\}_{i \notin S_k}$.
      Solve the ER-DRO problem below at covariate $\bar{x}$ to get solution $\hat{z}^{DRO}_{-k}(\bar{x}, \zeta)$
      $$\min_{z \in Z} \sup_{Q \in \hat{\mathcal{P}}_{-k}(\bar{x})} \mathbb{E}_{Y \sim Q}\big[c(z, Y)\big],$$
      where the ambiguity set $\hat{\mathcal{P}}_{-k}(\bar{x})$ with radius ζ is centered at the estimated empirical distribution $\hat{P}^{ER}_{-k}(\bar{x}) := \dfrac{1}{n - |S_k|} \displaystyle\sum_{i \notin S_k} \delta_{\hat{f}_{-k}(\bar{x}) + \hat{\varepsilon}^i_{-k}}$.
    end for
  end for
end for
Output: Radius $\zeta_n \in \arg\min_{\zeta \in \Delta} \dfrac{1}{T} \displaystyle\sum_{\bar{x} \in \bar{\mathcal{X}}} \frac{1}{K} \sum_{k \in [K]} \frac{1}{|S_k|} \sum_{i \in S_k} c\big(\hat{z}^{DRO}_{-k}(\bar{x}, \zeta),\, y^i\big)$ for the ambiguity set $\hat{\mathcal{P}}_n(x)$ for the ER-DRO problem (7).

Algorithm 3 Specifying a covariate-dependent radius $\zeta_n(x)$ using the ER-DRO problem

Input: data $\mathcal{D}_n$, set of candidate radii Δ, number of folds K, and new covariate realization $x \in \mathcal{X}$.
Partition $[n]$ into subsets $S_1, \ldots, S_K$ of (roughly) equal size at random. Let $\mathcal{D}_{-k} := \mathcal{D}_n \setminus \{(y^i, x^i)\}_{i \in S_k}$.
for $k = 1, \ldots, K$ **do**
  for $\zeta \in \Delta$ **do**
    Fit a regression model $\hat{f}_{-k}$ using the data $\mathcal{D}_{-k}$ and compute its in-sample residuals $\{\hat{\varepsilon}^i_{-k}\}_{i \notin S_k} := \{y^i - \hat{f}_{-k}(x^i)\}_{i \notin S_k}$.
    Solve the ER-DRO problem below at covariate x to obtain solution $\hat{z}^{DRO}_{-k}(x, \zeta)$
    $$\min_{z \in Z} \sup_{Q \in \hat{\mathcal{P}}_{-k}(x)} \mathbb{E}_{Y \sim Q}\big[c(z, Y)\big],$$
    where the ambiguity set $\hat{\mathcal{P}}_{-k}(x)$ with radius ζ is centered at the estimated empirical distribution $\hat{P}^{ER}_{-k}(x) := \dfrac{1}{n - |S_k|} \displaystyle\sum_{i \notin S_k} \delta_{\hat{f}_{-k}(x) + \hat{\varepsilon}^i_{-k}}$.
    Fit a regression model $\hat{f}_k$ using the data $\{(y^i, x^i)\}_{i \in S_k}$ and compute its in-sample residuals $\{\hat{\varepsilon}^i_k\}_{i \in S_k} := \{y^i - \hat{f}_k(x^i)\}_{i \in S_k}$.
  end for
end for
Output: Radius $\zeta_n(x) \in \arg\min_{\zeta \in \Delta} \dfrac{1}{K} \displaystyle\sum_{k \in [K]} \frac{1}{|S_k|} \sum_{i \in S_k} c\big(\hat{z}^{DRO}_{-k}(x, \zeta),\, \hat{f}_k(x) + \hat{\varepsilon}^i_k\big)$ for the ambiguity set $\hat{\mathcal{P}}_n(x)$ for the ER-DRO problem (7).