1 2단계 구조의 ER-DRO 모형 (CVaR형 ambiguity set)

데이터: (x^k, p^k), $k = 1, \dots, N$. 예를 들어 로보택시가 운영된 도시–기간 단위로 관측된 context x^k(무차량 가구 비율)와 로보택시 선택확률 p^k 이다. 회귀로 $\hat{f}$ 와 로짓 척도의 잔차 $\hat{\varepsilon}^k = \mathrm{logit}(p^k) - (\hat{\beta}_0 + \hat{\beta}_1 x^k)$ 를 얻고(§3.2), 후보 도시 c의 context x_c에 잔차를 하나씩 붙여 시나리오 D_c^s를 생성한다. 잔차 하나가 시나리오 하나에 대응하므로 시나리오 집합 S는 잔차 인덱스 집합이고 $|S| = N$ 이다. 아래에서는 모형을 1단계 문제 (1), 시나리오별 2단계 문제 (3), 그리고 실제로 풀이하는 확장형(extensive form) (4)로 나누어 쓴다. 1단계 변수는 (y, q) 이고, 2단계 변수 (O^s, U^s)는 시나리오 s마다 분리된다. 차량 1대당 배치·운영비는 별도의 항으로 두지 않는다. 모형의 모든 항이 통행 단위로 표현되므로 대당 비용 K_c는 용량 1통행당 비용 K_c/κ_c로 환산되어 c_c^+, c_c^-에 흡수되며(§1.5), 이를 독립된 항으로 두어도 최적해는 바뀌지 않는다.

1.1 1단계 문제

$$\min_{y,q} \quad \underbrace{\sum_{c \in C} F_c y_c}_{\text{진입 비용}} + \underbrace{\mathcal{R}_\zeta(q)}_{\text{시나리오 페널티의 CVaR}} \tag{1a}$$

$$\text{s.t.} \quad 0 \le q_c \le \bar{q}_c\, y_c, \qquad \forall c \in C, \tag{1b}$$

$$\sum_{c \in C} q_c \le Q, \tag{1c}$$

$$y_c \in \{0,1\},\ q_c \in \mathbb{Z}_{\ge 0}, \qquad \forall c \in C. \tag{1d}$$

여기서 $\mathcal{R}_\zeta(q)$는 2단계 비용 $H(q, D^s)$의 시나리오 분포에 대한 CVaR이며, Rockafellar–Uryasev의 threshold 표현으로

$$\mathcal{R}_\zeta(q) = \min_{\tau \in \mathbb{R}} \left\{ \tau + \frac{1}{|S|(1-\zeta)} \sum_{s \in S} \big(H(q, D^s) - \tau \big)^+ \right\} \tag{2}$$

로 쓴다. $\zeta = 0$이면 $\mathcal{R}_0(q) = \frac{1}{|S|}\sum_s H(q, D^s)$가 되어 ER-SAA(표본평균)로 환원된다. Context x_c는 시나리오 값 $D_c^s = M_c p_c^s$에만 들어가고 최적화 구조는 바뀌지 않는다.

1.2 2단계 문제 (시나리오별 recourse)

1단계 결정 q와 시나리오 s의 수요 $D^s = (D_c^s)_{c \in C}$가 주어졌을 때 2단계 비용은

$$H(q, D^s) = \min_{O^s, U^s} \quad \sum_{c \in C} \big(c_c^+ O_c^s + c_c^- U_c^s \big) \tag{3a}$$

$$\text{s.t.} \quad \kappa_c q_c - D_c^s = O_c^s - U_c^s, \qquad \forall c \in C, \tag{3b}$$

$$O_c^s,\ U_c^s \ge 0, \qquad \forall c \in C. \tag{3c}$$

(3)은 c별로도 분리되며, 최적해는 닫힌 형태 $O_c^s = (\kappa_c q_c - D_c^s)^+$, $U_c^s = (D_c^s - \kappa_c q_c)^+$ 이다. 따라서 $H(q, D^s) = \sum_c \big[c_c^+ (\kappa_c q_c - D_c^s)^+ + c_c^- (D_c^s - \kappa_c q_c)^+ \big]$는 q에 대해 볼록인 조각별 선형 함수이고, 이것이 2단계 분해(L-shaped) 적용의 근거가 된다. 이 2단계 비용은 신문판매원(newsvendor) 문제의 과잉·부족 비용과 같은 구조이며, 1단계 결정 q는 (2)의 CVaR을 통해서만 2단계와 연결된다.

1.3 확장형 (extensive form): 실제로 풀이하는 MILP

(2)의 $(\cdot)^+$를 변수 w^s로 선형화하고 (3)을 (1)에 합치면 다음 단일 MILP를 얻는다. (4b)–(4c), (4g)–(4h)는 시나리오별로 분리되는 2단계 제약이고, (4d)–(4f)는 1단계 제약이다.

$$\min_{y,q,O,U,\tau,w} \quad \sum_{c \in C} F_c y_c + \tau + \frac{1}{|S|(1-\zeta)} \sum_{s \in S} w^s \tag{4a}$$

$$\text{s.t.} \quad w^s \ge \sum_{c \in C} \big(c_c^+ O_c^s + c_c^- U_c^s \big) - \tau, \qquad \forall s \in S, \tag{4b}$$

$$\kappa_c q_c - D_c^s = O_c^s - U_c^s, \qquad \forall c \in C,\ s \in S, \tag{4c}$$

$$0 \le q_c \le \bar{q}_c\, y_c, \qquad \forall c \in C, \tag{4d}$$

$$\sum_{c\in C} q_c \le Q, \tag{4e}$$

$$y_c \in \{0,1\},\ q_c \in \mathbb{Z}_{\ge 0}, \qquad \forall c \in C, \tag{4f}$$

$$O_c^s,\ U_c^s \ge 0, \qquad \forall c \in C,\ s \in S, \tag{4g}$$

$$w^s \ge 0,\ \ \tau \in \mathbb{R}, \qquad \forall s \in S. \tag{4h}$$

1.4 변형: 진입 비용을 예산 제약으로

진입 가능한 도시 수(또는 진입 예산)가 실제 제약이라면, (4a)의 $\sum_c F_c y_c$를 목적함수에서 제거하고 다음 제약을 추가한다.

$$\sum_{c\in C} F_c y_c \le B \qquad \text{또는} \qquad \sum_{c\in C} y_c \le B. \tag{5}$$

이 변형에서는 목적함수가 $\tau + \frac{1}{|S|(1-\zeta)}\sum_s w^s$, 즉 2단계 페널티의 CVaR만 남는다. 이 변형은 y의 조합을 직접 제한하므로 2단계 분해 시 초기 master 문제가 자명해($y = q = 0$) 반복이 길어지는 문제를 완화한다.

1.5 대당 비용의 흡수 : K_c 항 빼는 이유

차량 1대당 비용 K_c(배치·운영비)를 목적함수에 $\sum_c K_c q_c$로 두더라도, (4c)에 의해 모든 s에서 $\kappa_c q_c = D_c^s + O_c^s - U_c^s$이므로 $\zeta = 0$일 때

$$\sum_c K_c q_c + \frac{1}{|S|}\sum_s\sum_c \left(c_c^+ O_c^s + c_c^- U_c^s\right) = \underbrace{\frac{1}{|S|}\sum_s\sum_c \frac{K_c}{\kappa_c} D_c^s}_{\text{결정과 무관한 상수}} + \frac{1}{|S|}\sum_s\sum_c \left[\left(c_c^+ + \frac{K_c}{\kappa_c}\right)O_c^s + \left(c_c^- - \frac{K_c}{\kappa_c}\right)U_c^s\right] \tag{6}$$

이 성립한다. 즉 K_c는 $c_c^+ \leftarrow c_c^+ + K_c/\kappa_c$, $c_c^- \leftarrow c_c^- - K_c/\kappa_c$의 재정의와 동치이며($\zeta > 0$에서는 $(K_c/\kappa_c)D_c^s$가 CVaR 안에 들어가 근사), 독립된 결정 레버가 아니다. 또한 K_c가 도시 간에 같고 (4e)가 등호로 묶이면 $\sum_c K_c q_c = KQ$로 상수이다. 따라서 본 연구는 K_c를 별도 항으로 두지 않고, 대당 비용을 용량 1통행당으로 환산한 값을 c_c^+, c_c^-의 정의에 포함한다 생각하고 비율만 따진다(ex 1:5).

제약	단계	의미
$0 \le q_c \le \bar{q}_c y_c$ (4d)	1단계	도시에 진입하지 않으면 차량 0대, 진입하면 도시별 상한까지 배치 가능
$\sum_c q_c \le Q$ (4e)	1단계	총 차량 대수 제한
$\sum_c F_c y_c \le B$ (5)	1단계 (변형)	진입 예산(또는 진입 도시 수) 제한. 목적함수의 $\sum_c F_c y_c$를 대체
$\kappa_c q_c - D_c^s = O_c^s - U_c^s$ (4c)	2단계 (s별 분리)	서비스 용량과 로보택시 수요의 차이 = 잉여 용량 − 미충족 수요
$w^s \ge \sum_c (c_c^+ O_c^s + c_c^- U_c^s) - \tau$, $w^s \ge 0$ (4b),(4h)	2단계 (s별 분리)	시나리오 s의 페널티가 threshold τ를 초과하는 양. 최소화 과정에서 $w^s = (\text{penalty}_s - \tau)^+$가 된다

2 표기

2.1 Contextual 및 DRO 추가 표기

기호	의미	종류 및 단위
(x^k, p^k)	관측 k의 context(무차량 가구 비율)와 로보택시 선택확률	데이터; $k = 1, \dots, N$
x_c	후보 도시 c의 특성(공변량) 벡터. 현 단계에서는 무차량 가구 비율 하나	입력; Kannan의 새 관측 x에 대응
$\hat{f}$	추정된 회귀함수; $\hat{f}(x) \approx \mathbb{E}[p \mid x]$. 로짓 $\hat{f}(x) = \sigma(\hat{\beta}_0 + \hat{\beta}_1 x)$, $\sigma(z) = 1/(1+e^{-z})$	추정 함수
$\hat{\varepsilon}^k$	잔차 $\text{logit}(p^k) - (\hat{\beta}_0 + \hat{\beta}_1 x^k)$	유도량; 로짓 척도
ζ	CVaR형 ambiguity set의 반경(꼬리 비율). $1-\zeta$는 최악 그룹으로 남기는 시나리오 비율	입력; $[0, 1)$. $\zeta = 0$이면 ER-SAA
τ	페널티 threshold. 결정변수이며 최적해에서 "$\lvert S\rvert(1-\zeta)$ 번째로 큰 페널티"	결정변수; 화폐 단위
w^s	시나리오 s의 페널티가 τ를 초과하는 양	결정변수; 화폐 단위
$\mathcal{R}_\zeta(q)$	2단계 비용의 CVaR, 식 (2)	q의 함수; 화폐 단위
$H(q, D^s)$	시나리오 s의 2단계(recourse) 비용, 식 (3)	q의 함수; 화폐 단위

기호	의미	종류 및 단위
B	진입 예산 또는 진입 가능 도시 수 (변형 모형)	입력; 화폐 단위 또는 도시 수

2.2 기본 표기

기호	의미	종류 및 단위
C	후보 도시 집합	입력 집합; 도시
S	수요 시나리오 집합	입력 집합; 잔차 인덱스 집합, $\lvert S\rvert = N$
y_c	도시 c에 진입하면 1, 아니면 0	1단계 결정변수; 이진
q_c	도시 c에 배치하는 차량 대수	1단계 결정변수; 대 (정수)
κ_c	차량 한 대가 평가 기간 동안 처리할 수 있는 통행 수	척도 파라미터; 통행/대
Q	배치 가능한 총 차량 대수 (보유 차량; 취득비 · 감가상각은 매몰비용)	입력; 대
$\bar{q}_c$	도시별 차량 배치 상한	입력; 대
F_c	도시 진입 및 기본 인프라 고정비	입력; 평가 기간 화폐 단위
c_c^+	잉여 용량 1단위당 손실.	입력; 화폐/통행
c_c^-	미충족 잠재수요 1단위당 기회손실. 식 (6)	입력; 화폐/통행
M_c	도시 c의 1년간 **모든 수단을 합한 잠재 이동 기회** 수	입력; 이용 기회 수. 데이터 또는 가정
p_c^s	도시 c의 이동 기회가 로보택시를 선택할 확률	회귀로 생성; $[0,1]$. $p_c^s = \sigma(\hat{\beta}_0 + \hat{\beta}_1 x_c + \hat{\varepsilon}^s)$
D_c^s	로보택시 선택 수요	유도 입력; 통행. $D_c^s = M_c p_c^s$
O_c^s	잉여 서비스 용량	2단계 결과변수; 통행. $O_c^s = (\kappa_c q_c - D_c^s)^+$
U_c^s	미충족 로보택시 수요	2단계 결과변수; 통행. $U_c^s = (D_c^s - \kappa_c q_c)^+$

3 수치 실험: 합성 데이터

3.1 전체 흐름

참 수요 모형을 알고 있는 합성 환경에서 (i) 추정–최적화 파이프라인이 작동하는지, (ii) 참 모형이 있어야만 잴 수 있는 양(out-of-sample 비용, context의 가치, DRO의 효과)을 측정한다. 흐름은 다섯 단계이다.

1. 후보 도시 입력 $(x_c, M_c, \kappa_c, \bar{q}_c, F_c)$과 참 수요 모형 $p = \sigma(\beta_0 + \beta_1 x + \varepsilon)$을 설정한다.
2. 참 모형에서 훈련 자료 $(x^k, p^k)_{k=1}^N$을 생성하고 로짓 OLS로 $\hat{f}$와 잔차 $\hat{\varepsilon}^k$를 추정한다.
3. 후보 도시별 시나리오 $D_c^s = M_c\,\sigma(\hat{\beta}_0 + \hat{\beta}_1 x_c + \hat{\varepsilon}^s)$를 만들어 확장형 (4)를 푼다.
4. 참 모형에서 따로 생성한 평가 시나리오 1,000개로 해 (y, q)의 out-of-sample 기대비용과 꼬리비용을 계산한다.
5. 설정 (N, c^-, ζ)을 바꾸어 가며 2–4를 반복하고, context 없는 벤치마크 및 변형 (5)과 비교한다.

3.2 합성 데이터 생성

후보 도시 입력. 후보 도시는 Waymo가 공표한 향후 진출 후보 18개 도시이다. 각 도시를 중심 county 하나로 대응시키고(예: Chicago → Cook County), context x_c는 ACS 2019–2023 5년 추정 표 B08201의 무차량 가구 비율 실제값을 쓴다 (범위 0.054–0.777; New York County 0.777은 맨해튼만 포함한 극단값). 잠재 이동 기회 M_c는 같은 ACS 표의 총 가구 수에 비례상수 10을 곱해 두었으며, 이 비례상수는 toy용 가정이다 (실데이터에서는 NHTS × ACS 교차분류로 대체). 나머지 입력은 모든 도시에 공통으로 둔다 (표 4).

참 수요 모형. 도시 c의 수요는 $D_c = M_c\,p_c$이고 불확실성은 선택확률 p_c에만 둔다. 참 모형은

$$\operatorname{logit}(p) = \beta_0 + \beta_1 x + \varepsilon, \qquad \varepsilon \sim N(0, \sigma_\varepsilon^2) \tag{7}$$

이다. 로짓 형태를 쓰는 이유는 두 가지이다. 첫째, p는 "이동 기회 하나가 로보택시를 선택할 확률"이므로 선택확률을 설명변수의 함수로 두는 표준형이 이산선택의 로짓이며, $p \in (0,1)$과 x에 대한 단조성이 자동으로 보장된다. 둘째, 관측된 로보택시 수요를 분석한 유일한 연구인 Loa et al. (2026)이 $\ln(\text{통행} + 1)$을 종속변수로 한 로그-선형 공간시차 모형에서 무차량 가구 비율을 양(+)이고 유의한 변수(계수 0.008/%p, $t = 7.4$)로 보고하였고, $D = Mp$에서 로그-선형 통행 모형은 p가 작을 때 $\operatorname{logit}(p) \approx \ln p$와 같은 형태이다. 따라서 $\beta_1 = 0.8$은 그 계수를 0–1 척도로 환산한 값이다.

기본 파라미터. 비용은 $c^+ = 1$로 정규화하고 c^-를 $1, 5, 10$으로 바꾼다(과잉 대 부족 비용 비율 $c^+ : c^-$가 결정에 미치는 영향 확인 목적). 진입비는 $F_c = F_0\, c^-$로 두어 "진입비 대 미충족 마진" 비율이 c^-와 무관하게 유지되도록 하였다.

Table 4: 기본 파라미터와 설정 근거

파라미터	값	근거
x_c	ACS 실제값 (0.054–0.777)	ACS 2019–2023 B08201, county 단위
M_c	총 가구 수 $\times$ 10	가구 수는 ACS 실제값; 비례상수는 toy용 가정
κ_c	8,760 통행/대/년	24통행/일 $\times$ 365일. Waymo 공개 수치(주당 유료 탑승 약 50만 건, 2026년 3월; 차량 3,000대 이상, 2025년 12월)에서 역산한 대당 일 24건
$\bar{q}_c$	150 대	가정 (민감도 50–300)
Q	$0.6 \times \mathbb{E}[\sum_c D_c]/\kappa$	가정. 평균 수요의 60%만 처리 가능하도록 하여 배분이 비자명
F_0	10^5 ($c^- = 1$ 기준)	가정 (민감도 0.25×10^5– 4×10^5)
$c^+ : c^-$	$1:1,\ 1:5,\ 1:10$	가정
$\beta_0, \beta_1, \sigma_\varepsilon$	$-3.5,\ 0.8,\ 0.3$	β_1은 Loa et al. 환산값; $\beta_0, \sigma_\varepsilon$은 가정
N	15, 200	도시–기간 관측 규모를 부족/충분 경우로 가정. 훈련 관측 수 = 시나리오 수 $\lvert S\rvert$
ζ	0, 0.5, 0.9	0 = ER-SAA; 0.9 = 기본값
평가 시나리오	1,000	임의 가정

3.3 훈련 자료와 평가 자료

훈련 자료. "로보택시가 이미 운영된 도시–기간에서 관측된 (x, p)"를 흉내 낸다. 후보 도시 x_c의 범위에서 임의의 x^k를 균등 추출하고, 참 모형 (7)에서 ε^k를 뽑아 p^k를 계산한다 ($k = 1, \ldots, N$). 모형은 참 계수를 모른 채 이 N개로 $\hat{\beta}_0, \hat{\beta}_1$과 잔차 $\hat{\varepsilon}^k$를 추정하고, 최적화는 그 추정치로 만든 시나리오만 본다. 실데이터에서는 이 단계가 $x =$ ACS 비율, $p =$ 로보택시 통행 수/M 인 관측 표로 대체된다.

평가 자료. "결정을 내린 뒤 실제로 닥친 수요"를 흉내 낸다. 후보 도시의 실제 x_c에 참 계수를 넣고 훈련과 독립인 ε 1,000개를 뽑아 D_c^{eval} (후보 도시 18개 $\times$ 1,000)를 만든다. 최적화는 이 자료를 보지 못하며, 해 (y, q)가 정해진 뒤 식 (3)의 닫힌 형태로 시나리오별 비용을 계산해 평균(기대비용)과 상위 10% 평균(꼬리비용, $\text{CVaR}_{0.9}$)으로 채점한다. 평가 자료는 N과 무관하게 고정되어 있어 $N = 15$와 $N = 200$으로 내린 결정을 같은 잣대로 비교할 수 있다. 훈련 자료로 채점한 값(in-sample)은 최적화가 그 자료에 맞춰졌으므로 실제보다 낙관적이며, 표 7에서 in-sample과 OOS가 다른 이유이다.

풀이 방법 비교: 확장형 vs. L-shaped 분해. 2단계 모형 (1)–(3)를 (i) 확장형 (4)로 통째로 푸는 방법과 (ii) master (y, q, τ)와 시나리오별 subproblem으로 나누는 multi-cut L-shaped 분해로 각각 풀었다 ($N = 15$, $c^- = 5$, $\zeta = 0.9$; 분해는 $\text{UB} - \text{LB} \le 10^{-2}\,|\text{UB}|$, 즉 상대 허용오차 1%에서 종료).

Table 5: 확장형과 L-shaped 분해의 비교

설정	방법	목적값	시간	비고
$B = 3$	확장형	16,036,515	0.4 s	진입: Chicago, New York, San Diego
	L-shaped	16,140,861	29.5 s	38회 반복, 진입 동일, 차이 0.65%
B 없음	확장형	17,304,198	1.5 s	진입: Chicago, New York, Philadelphia, Seattle
	L-shaped	17,378,353	54.5 s	38회 반복, 차이 0.43%, 진입 도시 2곳 상이

L-shaped의 목적값은 확장형보다 $B = 3$에서 0.65%, B 없음에서 0.43% 높았고, 진입 도시는 $B = 3$에서는 동일하였으나 B 없음에서는 2곳이 달랐다. L-shaped가 돌려주는 값은 종료 시점의 실행가능해 비용(상계)이므로 이 차이는 허용오차에서 일찍 멈춘 결과이며, B 없음에서 다른 도시 조합이 0.43% 높은 비용으로 실행가능함을 보여준다. 계산시간은 확장형 0.4 s, 1.5 s에 대해 L-shaped 29.5 s, 54.5 s로 확장형이 훨씬 빨랐는데, 2단계 비용이 affine 두 개의 max라 확장형의 O, U 변수가 cut을 처음부터 모두 넣은 것과 같기 때문이다. $F_c y_c$ 항을 제약 B로 옮기면($\sum_{c \in C} y_c \le B$) 분해의 수렴 시간이 줄어든다. 이후 실험은 모두 확장형으로 풀고, decision-dependent 확장 시 다시 비교한다.

3.4 결과 분석

실험 설정은 §3.2와 같고, 참 모형에서 계산된 총 차량은 $Q = 267$대이다. 모든 해는 참 모형의 시나리오 1,000개로 OOS 평가한다(기대비용과 꼬리비용 = 최악 10% 평균). 아래 다섯 질문에 대해 답, 근거, 해당 표·그림 순으로 정리한다.

Q1. 로짓 p 회귀로 수요를 추정해도 되는가? 표 6에서 $N = 200$이면 $\hat{\beta}_1 = 0.67$, $\hat{\sigma}_\varepsilon = 0.30$으로 참값(0.8, 0.3) 근처를 회복한다. 잔차를 시나리오로 합쳐 쓰기 위한 조건(잔차가 x와 무관하게 평균 0, 분산 일정)은 그림 1의 잔차 산점도로 확인된다. 검정 R^2가 0.12–0.14로 낮은 것은 설정상 x가 수요 변동의 약 13%만 설명하기 때문이며, x 없이 평균만 쓰면 $R^2 \approx 0$이므로 x의 설명력은 작지만 분명히 있다.

Table 6: 로짓 OLS 추정 결과 (오차 지표는 p 척도, 검정 자료 1,000개)

N	$\hat{\beta}_0$	$\hat{\beta}_1$	$\hat{\sigma}_\varepsilon$	test MSE	test MAE	test ME	test R^2	no-context R^2
15	−3.655	1.114	0.325	0.0002	0.0101	0.0461	0.124	−0.011
200	−3.479	0.665	0.298	0.0002	0.0099	0.0479	0.143	−0.013
참값	−3.500	0.800	0.300					

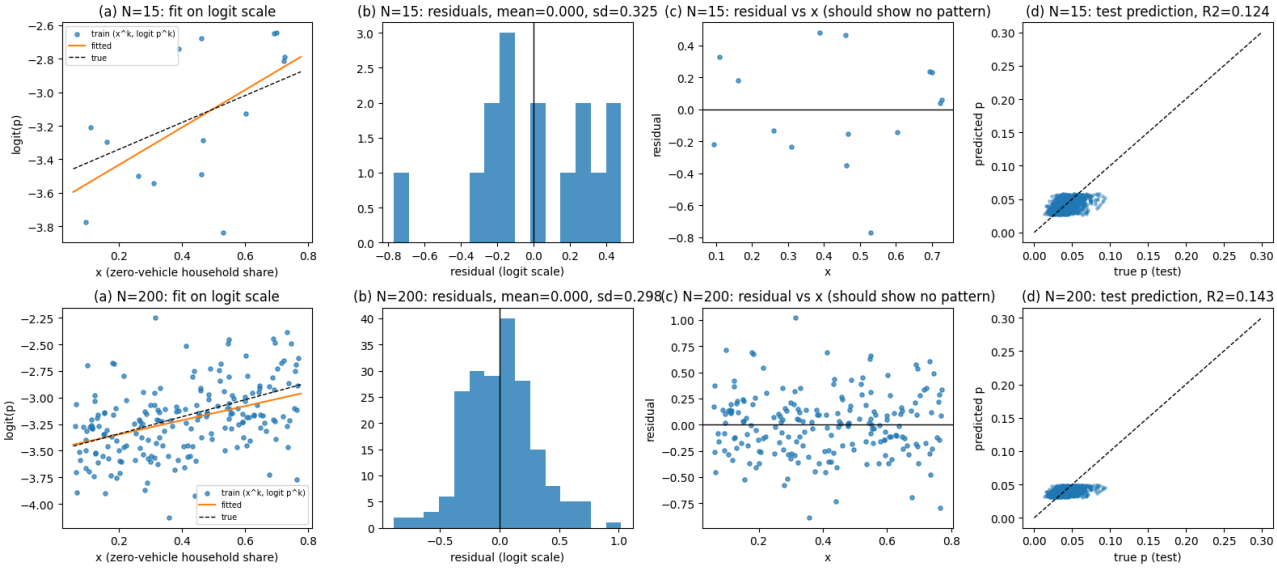


Figure 1: f 추정 진단. (a) 로짓 척도의 자료·적합선·참 직선, (b) 잔차 분포, (c) 잔차 대 x, (d) 검정 자료의 예측 p 대 실제 p. 윗줄 $N = 15$, 아랫줄 $N = 200$.

Q2. $c^+ : c^-$ 비율은 무엇을 쓰는가? 비율은 자료가 없어 선택하는 입력이며, 실험의 역할은 결론이 비율에 따라 바뀌지 않음을 보이는 것이다. 표 7에서 $c^- = 1, 5, 10$ 모두 (i) context 모형이 context 없는 모형보다 OOS 기대비용이 낮고, (ii) ζ가 커질수록 진입 도시 수가 줄며, (iii) Chicago와 New York은 18개 설정 모두에서, San Diego는 17개 설정에서 선택된다. 그림 3의 c^- 패널에서 비용은 c^-에 비례해 커지지만($c^- = 1, 2, 5, 10, 20$에서 3.08, 5.79, 14.22, 27.63, 54.45M) 세 모형의 상대 순서는 바뀌지 않는다. 따라서 기준 설정은 미충족이 잉여보다 비싼 1 : 5로 두고 나머지 비율은 보고만 한다.

Table 7: 설정별 최적 진입 도시 수, in-sample 목적값, OOS 비용 ($c^+ = 1$ 단위) 및 context 이득

N	c^-	ζ	진입 수	in-sample	OOS 평균	OOS 꼬리	no-ctx 평균	no-ctx 꼬리	이득
15	1	0	9	2,490,926	2,695,476	4,857,473	2,758,361	4,657,473	2%
		0.5	6	2,864,469	2,724,601	4,557,473	3,112,997	4,357,473	12%
		0.9	4	3,460,840	3,147,884	4,410,069	3,869,252	4,739,552	19%
	5	0	6	11,386,313	12,541,832	22,787,364	12,702,986	22,787,364	1%
		0.5	5	13,635,159	12,712,913	22,287,364	14,896,198	22,208,291	15%
		0.9	4	17,304,198	13,787,444	21,975,797	15,636,705	23,199,859	12%
	10	0	6	22,412,124	24,728,335	45,574,729	25,166,440	45,574,729	2%
		0.5	5	27,186,803	25,027,407	44,574,729	28,863,429	44,263,095	13%
		0.9	4	34,608,397	27,416,340	43,920,442	30,089,296	45,739,579	9%
200	1	0	8	2,599,840	2,662,764	4,757,473	2,748,503	4,657,473	3%
		0.5	6	3,054,078	2,712,652	4,557,473	2,980,460	4,457,473	9%
		0.9	4	4,415,710	3,084,216	4,357,473	3,727,040	4,610,719	17%
	5	0	6	12,225,772	12,463,377	22,787,364	12,722,661	22,787,364	2%
		0.5	5	14,870,099	12,674,534	22,287,364	13,031,319	22,287,364	3%
		0.9	3	22,045,780	14,222,971	21,617,923	14,901,907	22,265,378	5%
	10	0	6	24,168,288	24,654,132	45,574,729	25,128,612	45,574,729	2%
		0.5	5	29,646,948	24,957,044	44,574,729	25,611,150	44,574,729	3%
		0.9	3	44,013,689	27,629,179	43,180,752	28,889,111	44,519,917	4%

Q3. 왜 contextual ER-DRO인가, 조건은 만족하는가? 조건은 Q1에서 확인되었다(잔차의 x 독립성과 $\hat{f}$의 일치성). 효과는 두 부분이다. *Context*의 효과: 표 7에서 context 모형의 OOS 기대비용 이득은 $\zeta = 0$에서 1–3%, $\zeta = 0.5$에서 3–15%, $\zeta = 0.9$에서 4–19%이다. 이득이 작은 것은 $\beta_1 = 0.8$에서 x의 설명력이 작기 때문이며, 그림 3의 β_1 패널에서 $\beta_1 = 0$이면 두 모형의 비용이 같고 $\beta_1 = 0.8, 1.5, 3, 5$에서 이득은 1%, 16%, 25%, 41%로 커진다. *DRO*의 효과: ζ는 기대비용과 꼬리비용을 맞바꾼다. $N = 200$, $c^- = 5$에서 $\zeta = 0 \to 0.5 \to 0.9$일 때 기대비용은 12.46 → 12.67 → 14.22M(+1.7%, +14%), 꼬리비용은 22.79 → 22.29 → 21.62M(−2.2%, −5.1%)이다(그림 2). 한편 context 없는 모형은 $N = 15$, $\zeta = 0.9$에서 꼬리비용이 오히려 $\zeta = 0$보다 커진다($c^- = 5$: 22.79M→23.20M; $c^- = 1, 10$도 동일). x 없이 잔차 15개만으로 꼬리를 맞추려다 생기는 현상이며, DRO는 context와 함께 써야 함을 뜻한다.

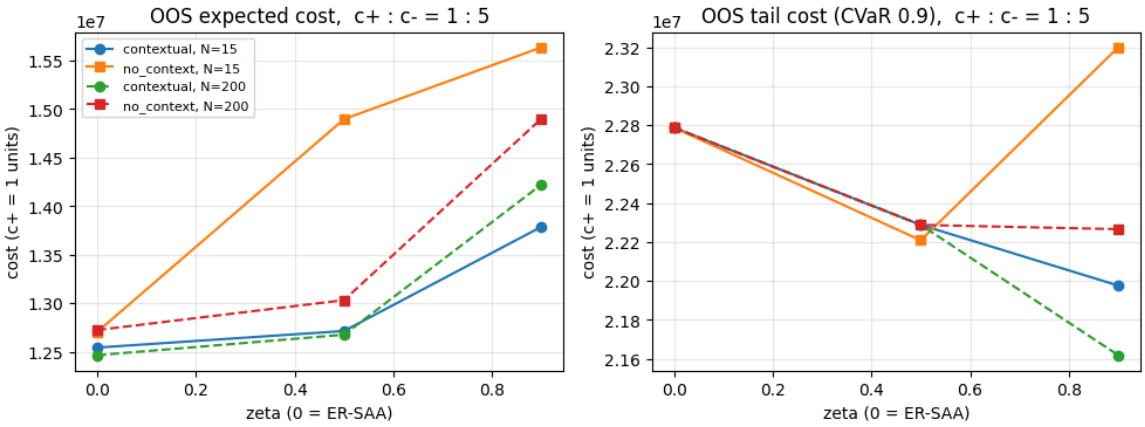


Figure 2: ζ에 따른 OOS 기대비용(좌)과 꼬리비용(우), $c^+ : c^- = 1 : 5$.

Q4. 자료가 적어도 이 모형을 써도 되는가? context를 쓰면 된다. 표 7의 $\zeta = 0.9$ 행에서 $N = 15$와 $N = 200$의 OOS 기대비용 차이는 $c^- = 1, 5, 10$에서 2.1%, 3.1%, 0.8%, 꼬리비용 차이는 1.2–1.7%이다. $\hat{\beta}_1$이 $N = 15$에서 39% 과대추정되고 $\zeta = 0.9$에서는 상위 2개 시나리오만 목적함수에 들어가는데도 그렇다. 그림 3의 N 패널에서 ER-SAA(context)는 $N = 10$부터 200까지 1.4% 안에서 평평하고, ER-DRO(context)는 13.19–14.24M, context 없는 모형은 14.38–16.14M으로 흔들린다. 즉 자료가 적을수록 context 모형의 이점이 커진다.

Q5. 민감도. 그림 3는 기준 설정($N = 200$, $c^- = 5$, $\zeta = 0.9$)에서 파라미터를 하나씩 바꾼 결과이다. 진입비 F_0와 변동성 σ_ε이 오르면 비용이 오르고(F_0: 12.04→18.73M), 총 차량 Q와 대당 처리량 κ가 오르면 비용이 내린다(Q 비율 0.2→1.0: 16.79→11.45M). Q가 평균 수요의 20%로 작으면 세 모형의 비용이 거의 같아지는데, 차량이 어떻게 배분해도 전부 쓰이기 때문이다. 도시별 상한 $\bar{q}_c$는 ER-SAA에서는 100 이상, ER-DRO에서는 150 이상에서 결과를 바꾸지 않는다. 표 8의 변형 (5)에서는 진입 도시 수 $B = 2, 3, 5$로 늘릴수록 2단계 비용이

내려가고($N = 200$, $c^- = 5$: 14.57→12.73→11.74M), 처음 세 도시는 N과 c^-에 무관하게 Chicago, New York → San Diego 순으로 안정적이다. $B = 5$의 구성은 N에 따라 달라지며, $N = 200$, $c^- = 5, 10$에서는 New York 대신 Philadelphia, Pittsburgh, Tampa가 들어온다.

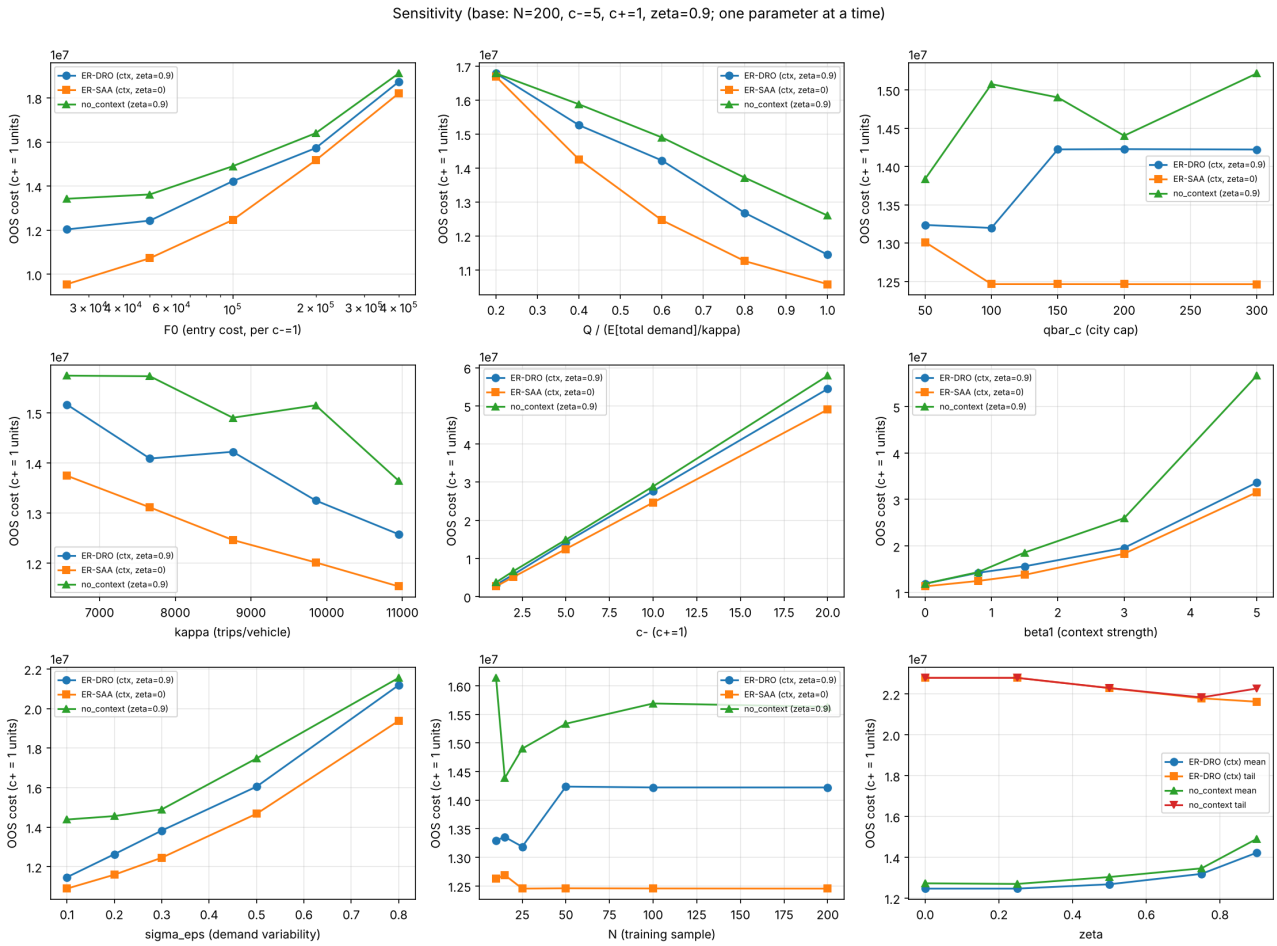


Figure 3: 민감도 분석. 기준 $N = 200, c^- = 5, c^+ = 1, \zeta = 0.9$에서 파라미터를 하나씩 변경. 선: context ER-DRO ($\zeta = 0.9$), context ER-SAA ($\zeta = 0$), context 없음 ($\zeta = 0.9$).

Table 8: 변형 (5): 진입 도시 수 B에 따른 OOS 2단계 비용과 선택 도시 ($\zeta = 0.9$)

N	c^-	B	OOS 2단계 비용	진입 도시
15	1	2	3,315,579	Chicago, New York
		3	3,084,918	+ San Diego
		5	2,358,358	+ Philadelphia, Seattle
	5	2	14,339,887	Chicago, New York
		3	12,668,561	+ San Diego
		5	10,305,798	+ Philadelphia, Seattle
	10	2	28,111,826	Chicago, New York
		3	24,631,627	+ San Diego
		5	20,068,402	+ Philadelphia, Seattle
200	1	2	3,395,462	Chicago, New York
		3	3,198,004	+ San Diego
		5	2,440,092	+ Detroit, Philadelphia
	5	2	14,572,482	Chicago, New York
		3	12,726,413	+ San Diego
		5	11,735,447	Chicago, Philadelphia, Pittsburgh, San Diego, Tampa
	10	2	28,274,685	Chicago, New York
		3	24,625,772	+ San Diego
		5	22,821,183	Chicago, Philadelphia, Pittsburgh, San Diego, Tampa

요약. (Q1) 로짓 p 회귀는 참 계수를 회복하고 잔차 합동 조건을 만족한다. (Q2) 결론은 $c^+ : c^-$ 비율에 둔감하므로 $1:5$를 기준으로 둔다. (Q3) context는 x가 수요를 좌우하는 정도만큼 비용을 줄이고(현 설정 1–3%, 강한 context 25–41%), DRO는 기대비용을 내주고 꼬리비용을 줄이며, 둘은 함께 써야 한다. (Q4) 관측 15개로도 비용이 3% 안에서 유지된다. (Q5) 비용은 $Q, \kappa, F_0, \sigma_\varepsilon$의 규모에 민감하고, Chicago와 New York은 모든 설정에서, San Diego는 17/18 설정에서 선택된다.

==========

4 실데이터 적용 계획

4.1 기호별 사용 자료

Table 9: 모형 입력과 실데이터 출처

입력	실데이터	출처	단위
p^k (훈련 종속변수)	로보택시 통행 수 $\div M^k$	CPUC AV Passenger Service 분기 보고서 (사업자 제출; 캘리포니아)	tract × 기간
x^k (훈련 context)	무차량 가구 비율	ACS 5년 추정 B08201 (`_002E/_001E`)	tract
M^k (훈련)	$\sum_g$ (차량 g대 보유 가구 수)×(NHTS g집단 통행률)× 일수	ACS B08201 (`_002E`–`_006E`) + NHTS 2022	tract × 기간
x_{cj} (후보 도시 tract)	무차량 가구 비율	ACS B08201, 후보 county 안의 tract	tract
M_{cj} (후보 도시 tract)	위와 같은 공식, 연 단위	ACS + NHTS	tract × 년
κ	8,760 통행/대/년	Waymo 공개 수치 역산	–
Q, $\bar{q}_c$, F_0	toy와 같은 가정	–	–
$c^+ : c^-$	1:1, 1:5, 1:10	비용 자료 없음 → 비율	–
ζ	0.9 고정	–	–

4.2 절차

운영 도시(샌프란시스코 등)의 tract $k = 1, \ldots, N$에서 x^k, M^k, 통행 수 T^k를 관측하고 $p^k = T^k/M^k$로 둔다. 후보 도시 c의 tract $j \in J_c$에는 x_{cj}, M_{cj}만 있다(통행 없음).

1. 회귀 (운영 도시 tract).

$$\operatorname{logit}(p^k) = \beta_0 + \beta_1 x^k + \varepsilon^k, \qquad (\hat\beta_0, \hat\beta_1) = \arg\min_{\beta} \sum_{k=1}^{N} \big(\operatorname{logit}(p^k) - \beta_0 - \beta_1 x^k\big)^2, \qquad \hat\varepsilon^k = \operatorname{logit}(p^k) - \hat\beta_0 - \hat\beta_1 x^k. \tag{8}$$

2. 시나리오 (후보 도시 tract에 적용; 잔차 하나 = 시나리오 하나).

$$p^s_{cj} = \sigma\big(\hat\beta_0 + \hat\beta_1 x_{cj} + \hat\varepsilon^s\big), \qquad D^s_c = \sum_{j \in J_c} M_{cj}\, p^s_{cj}, \qquad s = 1, \dots, N. \tag{9}$$

c는 후보도시, j는 그 도시 안의 tract(수요 계산 단위).

3. 최적화. D^s_c를 확장형 (4)에 넣어 (y_c, q_c)를 구한다. 결정은 도시 단위, 수요는 tract 합이다.

4. 도시 간 교차검증. CPUC 자료에 San Francisco와 LA 도 있다. 샌프란시스코 tract들로 $\hat f$ 추정하고 LA tract의 x를 넣어 예측한 p를 LA의 실제 p와 비교한다.(MAE, R^2, 잔차 평균 0인지, 퍼짐이 SF 잔차와 같은지) 만약 LA 잔차 평균이 0에서 크게 벗어나면 외삽에 한계가 있다는 것이다.

4.3 전제 조건

1. **같은 관계(외삽)**: 운영 도시 tract에서 추정한 β_0, β_1이 후보 도시 tract에도 그대로 성립한다.
2. **잔차 합동(pooling)**: ε의 분포가 tract와 x에 무관하다(평균 0, 등분산). 그래야 운영 도시의 잔차를 후보 도시 어느 tract에나 붙일 수 있다.
3. **같은 단위**: 추정과 적용이 같은 공간 단위(tract)이고, p의 분자·분모가 같은 기간이며, M이 두 도시에서 같은 공식으로 계산된다.
4. **범위 안**: 후보 tract의 x_{cj}가 훈련 x^k의 범위 안에 있다.
5. **수요 외생성**: p가 결정 q_c에 의존하지 않는다(decision-independent; 이후 확장에서 완화).

4.4 작은 숫자 예시

샌프란시스코(운영 중)에 tract 3개, 시카고(후보)에 tract 2개만 있다고 하자. 기간은 1년이다.

SF tract	가구 수	무차량 가구	x	M (가구×10)	로보택시 통행 (CPUC)	p = 통행/M
A	1,000	100	0.10	10,000	300	0.03
B	1,000	300	0.30	10,000	600	0.06
C	1,000	500	0.50	10,000	800	0.08

1단계. 훈련 자료 (샌프란시스코 tract). x와 가구 수는 ACS, 통행 수는 CPUC에서 온다. 관측은 $N = 3$개이다. 도시 단위로 하면 샌프란시스코 전체가 한 줄($N = 1$)이 되어 회귀가 불가능하므로 tract로 내려간다.

2단계. 회귀. $\operatorname{logit}(p)$를 x에 적합하면 $\hat\beta_0 = -3.67$, $\hat\beta_1 = 2.58$, 잔차 $\hat\varepsilon = (-0.07, +0.14, -0.07)$이다. 이 세 값이 그대로 시나리오 3개가 된다.

3단계. 후보 도시에 적용. 시카고에는 통행 자료가 없고 ACS만 있다.

Chicago tract	x	M
D	0.20	20,000
E	0.60	5,000

시나리오 1(잔차 -0.07): tract D의 $p = \sigma(-3.67 + 2.58 \times 0.20 - 0.07) = 0.0385$, tract E의 $p = \sigma(-3.67 + 2.58 \times 0.60 - 0.07) = 0.1012$, 수요 $D = 20{,}000(M_D) \times 0.0385(p_D) + 5{,}000(M_E) \times 0.1012(p_E) = 770 + 506 = 1{,}276$. 같은 식으로 시나리오 2(잔차 $+0.14$)는 $940 + 609 = 1{,}548$, 시나리오 3은 1,276이다. 이 세 값이 최적화의 D^s_{Chicago}, $s = 1, 2, 3$이다. 결정 (y, q)는 도시 하나에 대해 내리고, 수요만 tract 합으로 계산한다.

시간 단위. 위 표가 1년이 아니라 1개월이어도 $p = \text{통행}/M$은 같은 척도이므로 $\hat{f}$를 그대로 쓸 수 있고, 시카고 M을 연간으로 두면 연간 수요가 나온다. 다만 월 자료는 잔차가 더 퍼져 있어 시나리오의 변동이 커진다.