M을 정하는 과정 정리

1 요약

이 문서는 고정된 M을 정하는 과정을 정리하였다.

최초 회귀 추정하려 했던 M의 공변량이 p와도 영향을 줄 가능성이 커서 M을"전체 잠재 시장"이라고 정의한다. 이에 M_c을 고정된 값(도시별 특정 상수)로 정하여 도시별 (인구)×1인당 통행 발생량으로 산출한다. 데이터를 확인해보고 세부 산출 방법을 구상할 예정이고, 아래는 가이드라인만 제시한다.

2 이미 정해 놓은 후보군

`B. Candidates/candidates_(M,p)`에서 이미 자료조사를 통해 선별한 후보 driving factor들이 아래와 같다.

2.1 Driving factors of M

The papers below mainly explain **observed ride-hailing usage**, so they do not include the 'unrealized demand' included in the definition of M, making direct estimation impossible. However, I suppose the demand patterns provided by these papers lead to constructing 'potential travel opportunities M' through modeling.

Variable	Supporting paper	Scope established in the paper	Measurement data
Population and population density	Elkhouly and Alhadidi, *Ride-sharing Determinants* (paper); Zhang et al., *Examining spatial heterogeneity*⋯ (paper)	Relationship of population and local density with conventional ride-hailing usage. Density effects may vary by area	ACS
Employment and economic activity	Elkhouly and Alhadidi (paper)	Uses the economically active population and employment environment to explain usage	LEHD/LODES, ACS
Income	Elkhouly and Alhadidi (paper)	Analyzes the relationship between income and usage in Chicago	ACS B19013
Share of car-free households	Elkhouly and Alhadidi (paper)	Analyzes the relationship between households without cars and usage	ACS B08201
Land-use mix, accessibility, and commercial activity	Zhang et al., *Examining spatial heterogeneity*⋯ (paper)	Nonlinear and spatial differences in the urban environment and ridesourcing usage	EPA SLD
Restaurant and leisure-facility density	Loa, Lee, and Circella, *Just another ride-hailing?* (paper)	Relationship with **robotaxi trip counts in SF**. Does not separate the effects of M and p	Census CBP, OpenStreetMap
Public transport and walking environment	Zhang et al. (paper); Cats et al., *Beyond the dichotomy*⋯ (paper)	Analyzes the local environment and travel-time competitiveness and substitutability with public transport. Not a uniform increase/decrease effect	EPA SLD, GTFS
Airport-related market size	Zhang et al. (paper)	Analyzes airport travel as a separate spatial category. **Does not estimate the direct effect of airport passenger counts**	FAA passenger data. Used as a proxy for market size
Time, day of week, and season	Elkhouly and Alhadidi (paper)	Analyzes differences in usage over time. Specific variables such as holidays are selected through separate design	Dates and times in trip data

Variable	Supporting paper	Scope established in the paper	Measurement data
Weather	Additional: Liu, Jiang, and Chen, *Quantifying the impact of weather on ride-hailing ridership: Evidence from Haikou, China* (2021, paper)	Analyzes the relationship between weather and ride-hailing usage. Effects in U.S. cities require revalidation	NOAA CDO

※ Elkhouly & Alhadidi, / Loa, Lee, & Circella 논문에서와 같은 자료 모두 특정 도시 내의 구역을 대상으로 조사한 변수들이라 도시 전이 가정 필요하다.

3 M_c를 상수로 정하는 방법

방법	M_c 계산	필요한 자료	특징	선택여부
(a) 기준 도시 + 가정한 β	인구$_c \times m_{\text{ref}} \times \prod_k \left(\frac{x_{c,k}}{x_{\text{ref},k}}\right)^{\beta_k}$	기준 도시 1곳의 M	β는 가정이라 민감도 분석 필수	X
(b) 구역 회귀로 β 추정	same as (a)	기준 도시의 구역별 자료	구역 → 도시 전이 가정 필요 + β는 가정이라 민감도 분석 필수	X
(c) 인구집단별 통행률 교차분류	$\sum_g$ 인구$_{c,g} \times$ (집단 g의 1인당 통행률)	NHTS(미국 전국 가구통행조사)의 집단별 통행률 + ACS의 도시별 인구구성	교통계획의 표준적인 통행 발생 방법. 회귀 없이 모든 도시에 같은 정의로 적용 가능	O

4 (a), (b) 선택 시

For (a) and (b), β를 추정하고, 그 식에 각 후보 도시의 x_c와 인구를 넣어 M_c를 한 번 계산하는 방식이다. **단, 이 방식으로 계산한 M_c는 overall ride-hailing을 정의한 것으로, 기존에 정의한 잠재 시장 M_c에 적용하려면 전이 가정이 필요하다.**

$$M_c = \text{인구}_c \times m_{\text{ref}} \times \prod_k \left(\frac{x_{c,k}}{x_{\text{ref},k}}\right)^{\beta_k}$$

- m_{ref}: 기준 도시(예: 시카고)의 인구당 ride-hailing 통행
- β_k: 변수 k가 1% 오를 때 인구당 통행이 몇 % 오르는가(탄력성)
- **β를 정하는 방법**

방법	내용	특징
(a) $\beta = 1$ 가정	모든 변수에 대한 가중치 동일	단순 but β 민감도 실험 필수
(b) 기준 도시 **안의 구역** 자료로 추정	시카고 TNP 자료의 구역별 통행 + ACS 구역별 변수로 $\log(\text{통행}/\text{인구}) = a + \sum_k \beta_k \log x_k$ 회귀	관측 수가 많아 $n/10$ 기준 (rule of thumb) 충족. 구역 → 도시 전이 가정 필요

4.1 M의 driving factor 선택 기준

번호	기준	성격
1	문헌이 ride-hailing 이용량과 일관된 부호의 연관을 보고; 추정 부호가 어긋나면 제외·설명	사전 + 사후
2	모든 후보 도시에서 같은 출처·정의·지리 단위로 결정 시점에 구할 수 있음	사전
3	해석 가능; 변수 수 $\leq n/10$, 개념당 하나	사전
4	규모 무관 비율(인구당·면적당·가구당); 인구는 규모 인자로 분리	사전
5	결정 q와 무관(외생)	사전
6	후보 도시 값이 학습 데이터 범위 안	사전
7	적합 후 잔차가 x에 대해 패턴 없음(평균 0, 퍼짐 일정)	사후

4.2 각 기준에 대한 검토

1. 문헌에서 일관된 부호의 연관을 보고한 변수

- 의미: 특정 변수가 해석이 positive한 방향인지 negative한 방향인지 애매한 경우는 해석이 어려워져 배제한다. [사후 검증] 일관된 방향으로 해석이 나타나는 경우에도 추정 후 부호가 문헌과 어긋나면 제외하거나 설명한다.
- 주의점: 조사한 문헌의 factor들은 "관측된 ride-hailing 이용"에 대한 것이지 전체 잠재 시장 M에 대한 것이 아니다. 즉, "M에 확실히 영향"이라고 단정할 수 없으며, 선정한 변수는 "ride-hailing 이용량과의 연관"으로, M으로의 전이는 가정으로 명시한다.

2. 모든 후보 도시에 데이터가 있는 변수

- ① 같은 출처·같은 정의(예: ACS 5년 추정), ② 같은 지리 단위(시 경계 vs 광역권 vs 서비스 구역 — 섞이면 안 됨), ③ 결정 시점에 이미 있는 값(미래 자료 금지).

3. 해석 가능한 변수

- "어떤 context가 진입을 결정하는가"가 드러나는 변수를 고른다. 상관관계가 있는 변수 다수 선택은 가급적 배제한다 (ex. 밀도·무차량 가구·대중교통).

4. 규모 무관 비율

- 밀도는 면적당, 소득은 가구당, 공항은 인구당 이용객이라 전부 "인구당"은 아니다. 그리고 인구 자체는 공변량이 아니라 M = 인구 × (인구당 비율)의 규모 인자로 빠진다. 종속변수가 인구당 통행이면 공변량도 비율이어야 한다는 것이 정확한 규칙이다.

5. 외생 변수

- 결정 q에 따라 변하지 않는 변수. ex. "과거 ride-hailing 이용량"의 경우, M 쪽은 대부분 통과하지만, 공변량으로 쓰면 예측력은 최고인 대신 "왜"를 설명하지 못한다.

6. 후보 도시의 값이 학습 범위 안

- 범위 밖이면 $\hat{f}(x_c)$가 외삽이 되어 Kannan 가정 2의 예측오차가 커진다.

7. 공변량이 잔차와 무관

- 적합 후 점검 항목이다. OLS에서는 포함된 공변량과 잔차의 상관이 자동으로 0이라 기준으로는 아무것도 못 거른다. 의도한 것은 Kannan의 가정(잔차 분포가 x에 따라 달라지지 않음: 평균 0, 등분산성)이고, 이건 잔차 그림이나 이분산 검정으로 확인한다. 깨지면 종속변수를 비율·로그로 바꾸거나(4번이 이 역할) 빠진 변수를 넣는다. 이 기준은 "선택 후 확인: 잔차에 x에 대한 패턴이 없어야 하며, 있으면 변환 또는 변수 추가"로 읽는다.

4.3 후보군에 기준 적용: M

4.4 적용 표

기준 1–5를 driving factor 표의 각 변수에 적용한 결과이다. 6·7은 데이터와 회귀가 있어야 판정할 수 있으므로 "추후"로 둔다. 판정은 **선택** / **보류**(데이터·부호 확인 후 결정) / **제외**의 세 단계다. 기준 1 칸의 +는 해당 논문에서 확인한 부호이고, **"확인 필요"**는 표에 부호가 기록되어 있지 않아 원 논문에서 다시 확인해야 하는 항목이다.

변수	1	2	3	4	5	판정	이유 / 쓰는 형태
Population	–	○	○	×	○	분리	공변량이 아니라 규모 인자. $M = \text{인구} \times \hat{f}(x)$에서 곱해 주는 자리에 둔다 (기준 4).
Population density	△	○	○	○	○	보류	표에 "Density effects may vary by area". 지역에 따라 **크기**가 다른 것인지 **부호**가 뒤집히는 것인지 Zhang et al.에서 확인 후 결정. 둘 다 남으면 무차량 가구 비율과의 상관을 보고 기준 3(개념당 하나)으로 재검토.
Employment / economic activity	+	○	○	○	○	선택	Elkhouly & Alhadidi: 경제활동인구 비율 유의, 양의 효과. LEHD/LODES·ACS로 모든 도시 가능. 인구당 일자리 수 또는 경제활동인구 비율로 쓴다. 소득과의 상관 점검 필요(3.3).
Income	+	○	○	○	○	선택	Elkhouly & Alhadidi: 중위소득 유의, 양의 효과. ACS B19013으로 모든 도시 가능. 가구 중위소득(가구당 값). 단일 도시(시카고 구역) 근거이므로 도시 수준에서 부호 사후 확인 필수.
Share of car-free households	+	○	○	○	○	선택	Elkhouly & Alhadidi: 무차량 가구 비율 유의, 양의 효과. ACS B08201로 모든 도시 가능. 이미 가구 비율이라 기준 4 자연 충족. 해석이 가장 직접적(차가 없으면 호출 수요).
Land-use mix / accessibility	확인 필요	○	△	○	○	보류	표에 "Nonlinear and spatial differences". 비선형이어도 단조(부호 일정)일 수 있으므로 Zhang et al.에서 확인. 지수 형태라 해석은 간접적(기준 3 △).
Restaurant / leisure density	△	○	○	○	○	보류	근거가 SF 로보택시 통행 한 도시이고 M과 p 효과를 분리하지 못함. CBP로 데이터는 가능. p 쪽 후보로 재검토.
Public transport / walking	×	○	○	○	○	제외	표에 "Not a uniform increase/decrease effect"(대체·보완 양방향). 기준 1 탈락.
Airport-related market size	×	○	○	○	○	보류	"Does not estimate the direct effect"이고 대리변수. 인구당 공항 이용객으로 쓸 수는 있으나 기준 1을 못 넘으므로, 넣는다면 "대리변수"라고 명시하고 민감도로만.
Time / day of week / season	–	○	×	–	○	제외	도시 특성이 아니라 시간 변수. 연 단위 진입 결정에서는 평균에 묻힌다. 연도 추세 하나만 고려.
Weather	△	○	×	–	○	제외	근거가 중국 하이커우 자료이며 미국 재검증 필요(기준 1 불확실). 시간 변수라 연 단위 결정에서 평균에 묻힘.

4.5 추가 검토: ① 변수 간 상관 ② 분석 단위

(i) 경제활동인구 비율과 소득의 상관. 두 변수는 보통 양의 상관을 갖지만 같은 것은 아니다(대학 도시는 경제활동 비율이 높고 소득이 낮을 수 있고, 은퇴 인구가 많은 도시는 반대). 논문은 두 변수를 같은 공간회귀에 넣어 둘 다 유의하다고 보고했으므로, 시카고 구역 수준에서는 서로 구분되는 정보를 가진 셈이다. 우리 도시 수준 데이터에서는 다시 확인해야 한다: 상관계수와 VIF를 점검하고, 상관이 높으면(예: $|r| > 0.7$ 또는 VIF > 5) 기준 3(개념당 하나)에 따라 하나만 남긴다. 남기는 우선순위는 무차량 가구 비율(해석이 가장 직접적) > 소득 또는 경제활동 비율 중 하나.

(ii) 분석 단위의 전이. 논문은 시카고 한 도시 안의 구역 단위(community area 또는 census tract — 원 논문에서 확인) 공간회귀다. 우리는 도시 단위로 쓰려 한다. 도시 **안** 구역 사이에서 성립한 관계가 도시 **사이**에서도 성립한다는 보장은 없다(집계 수준이 바뀌면 관계가 달라질 수 있음). 따라서 기준 1의 근거는

"구역 수준 증거"라고 명시하고, 도시 수준 전이는 가정으로 두며, 기준 1의 사후 검증(도시 수준 데이터에서 부호 재확인)으로 보완한다. 도시 간 비교에서는 소득에 생활비 차이가 섞이므로 지역 물가로 조정하거나 상대값을 쓰는 것도 고려한다.

4.6 1차 선택 결과

- **선택(3개, 부호 확인됨)**: **경제활동인구 비율(또는 인구당 일자리), 가구 중위소득, 무차량 가구 비율**. 종속변수는 인구당 ride-hailing 통행량, 인구는 규모 인자로 분리. 셋 중 상관이 높은 쌍이 있으면 하나로 줄인다(3.3).
- **보류(4개)**: 밀도, 토지이용 혼합도(부호 반전 여부 확인), 식당·여가시설 밀도(p 쪽 후보로 이동 검토), 공항 이용객(대리변수로 민감도에서만).
- **제외(3개)**: 대중교통·보행 환경, 시간·요일·계절, 날씨.

4.7 (a), (b) 방식에 대한 결론

- 선택한 공변량(**경제활동인구 비율(또는 인구당 일자리), 가구 중위소득, 무차량 가구 비율**)이 M 보다 ride-hailing을 고르느냐(p)에 더 영향을 줄 가능성이 더 클 수 있다.
- 4.5의 내용에 따라 변수 간 상관과 구역 → 도시 전이 가정을 별도로 고려해야 한다.

5 (c) 선택 시

M_c를 **NHTS의 인구집단별 1인당 통행률 × 도시별 인구**로 구성한다. 이 방법으로 하면 회귀 없이 모든 후보 도시에 같은 정의로 계산하는 고정값이 산출된다.

세부적인 산출과정은 데이터를 직접 보고 다시 정리예정. 아래는 방법에 대한 가이드라인만 서술.

5.1 필요한 데이터

필요한 것	출처 (링크)	비고
인구집단별 1인당 통행률 r_g	NHTS (FHWA 전국 가구통행조사) 공개 마이크로데이터 (가구·개인·통행 파일): nhts.ornl.gov/downloads	응답자가 하루 통행일지를 기록. 가구 차량 수, 소득 구간, 가구원 수, 연령, 도시 규모 등 분류 변수와 통행 수단이 들어 있음. 2017 조사는 주(州) 추가표본 포함 약 13만 가구로 크고, 2022 조사는 표본이 훨씬 작으니 셀 수를 정할 때 주의
도시별 집단 인구 $N_{c,g}$	ACS 5년 추정 (모든 지리 단위에 제공): census.gov/programs-surveys/acs	집단을 두 변수 이상으로 교차할 때 표준 표에 없는 조합은 ACS PUMS(마이크로데이터, PUMA 단위 ≥ 10만 명)에서 직접 집계
도시 인구(규모 인자)	ACS B01003 또는 Census	
검증용 지역 가구통행조사	MPO 자료. 예: 시카고 CMAP cmap.illinois.gov, 뉴욕 NYMTC nymtc.org	총 통행량 비교로 오차 크기 확인

※ 링크는 작성 시점 기준이며, 표 번호(B08201 등)의 연도 접미사(ACSDT5Y2022)는 쓰는 ACS 연도에 맞게 바꾼다.
※ ACS 표 조회: data.census.gov.
※ ACS 표 예: B08201(가구원 수 × 보유 차량 수), B19001(가구 소득 구간), B01001(연령).
※ 교차 집계 ACS PUMS: census.gov/programs-surveys/acs/microdata
※ 집계 도구: data.census.gov/mdat

※ 둘 다 공개 자료이고 모든 후보 도시에 같은 정의로 적용되므로 기준 2(출처·정의·지리 단위 동일)를 만족한다. 단, NHTS 공개 파일은 도시를 직접 식별하지 않는다(주, 도시 규모 구간, 일부 대도시권 코드만). 그래서 "도시별 통행률"이 아니라 **"집단별 전국 통행률"을 도시의 인구 구성에 곱하는** 방식이 된다. 이것이 교차분류의 핵심이다.

5.2 절차

1. 집단 g를 정한다. 교통계획에서 통행 발생을 가장 잘 가르는 변수는 가구 차량 수와 소득이고, 최초 M_c의 공변량 선택과도 겹친다.

2. NHTS에서 r_g를 계산한다. 통행 파일을 집단별로 나누고, 가중치를 써서 집단 g의 연간 1인당 통행 수를 구한다

3. ACS에서 $N_{c,g}$를 구한다. 각 후보 도시에 대해 집단별 인구를 구한다. 차량 수 × 소득 교차는 표준 표에 없으므로 PUMS에서 PUMA별로 집계해 도시로 합친다. 가구 단위 자료이면 가구원 수를 곱해 사람 수로 바꾼다.

4. 곱해서 더한다. 모든 후보 도시에 같은 r_g를 쓰므로 도시 간 차이는 인구 규모와 구성에서만 나온다.

$$M_c = \sum_{g \in G} N_{c,g}\, r_g$$

인구를 규모 인자로 분리해 쓰면

$$M_c = \text{인구}_c \times \sum_{g \in G} \pi_{c,g}\, r_g, \qquad \pi_{c,g} = \frac{N_{c,g}}{\text{인구}_c}\ (\text{도시 } c\text{의 집단 구성비}),$$

즉 $\bar{r}_c = \sum_g \pi_{c,g} r_g$가 도시 c의 "구성 가중 1인당 통행률"이다.

5. 검증. 지역 교통계획기구(MPO)의 가구통행조사가 있는 도시(시카고 CMAP, 뉴욕 NYMTC 등)에서 총 통행량과 비교해 오차 크기를 보고, 그 크기를 M 민감도 범위로 쓴다.

$$e_c = \frac{M_c - M_c^{\text{MPO}}}{M_c^{\text{MPO}}}, \qquad \text{민감도 범위: } M_c \times \left(1 \pm \max_{c'} |e_{c'}|\right)$$

5.3 example

집단 g (차량 × 소득)	r_g (연간 1인당 통행)	도시 A 인구 $N_{A,g}$	$N_{A,g} \times r_g$
0대 × 저소득	900	60,000	54.0M
0대 × 중·고소득	1,000	40,000	40.0M
1대 × 저소득	1,100	150,000	165.0M
1대 × 중·고소득	1,250	250,000	312.5M
2대+ × 전체	1,350	500,000	675.0M
합계		1,000,000	$\boldsymbol{M_A = 1{,}246.5}$M

5.4 사전 정의

- **어떤 통행을 "이용 기회"로 볼 것인가.** 모든 사람 통행을 다 넣으면 M이 매우 커지고 p는 매우 작아진다. 걷기 300m 같은 통행은 로보택시로 대체될 기회가 아니므로, 예를 들어 "일정 거리 이상의 비도보 통행"으로 좁히는 선택지가 있다. NHTS에는 통행 거리와 수단이 있어 이 조건을 걸 수 있다:
- **지리 단위.** 로보택시 서비스 구역은 도시 전체가 아니라 대도시권 일부다. 시(place) 경계, 카운티, CBSA 중 하나로 고정하고 ACS도 같은 단위로 뽑아야 한다(기준 2).
- **연도.** 단위기간을 연도로 설정하였고 같은 연도의 데이터를 살피고 표본이 적정한 크기를 가져야 한다.

5.5 한계

- 집단별 통행률이 전국 공통이라는 가정이라, 밀도·대중교통 같은 도시 특성이 인구 구성을 통해서만 반영된다. 그 이상의 도시 효과를 넣으려면 (c) 구역 회귀와 결합해야 한다.
- 셀당 NHTS 표본이 작으면 r_g가 흔들린다. 셀 수를 줄이거나 표본이 큰 2017 자료를 쓰는 방안이 있다.
- p의 관측치는 같은 지리 단위에서 "로보택시 통행 / M_c"로 재야 분모가 맞는다. 로보택시 통행 수의 도시별 자료는 따로 확인이 필요하다.