EXPLAINER · CLUSTER C · CONTEXTUAL STOCHASTIC OPTIMIZATION

← 논문 지형도

Contextual SO를 그림으로 이해하기 — C2 · C3 · C4

한 문장으로: **“도시 특성 X를 봤으면, 결정도 X에 따라 달라져야 한다.”** C2는 방법의 지도를, C3는 X → 시나리오를 만드는 레시피를, C4는 그 시나리오를 못 믿을 때의 보험을 제공합니다.

`X = 도시 특성 (소득·인구밀도·POI·무차량 가구…)`
`D = 로보택시 수요`
`q = 배정 차량 수`
`c(q,D) = c⁺(q−D)⁺ + c⁻(D−q)⁺`

---

00 핵심 아이디어 — “평균 하나”에서 “도시마다 다른 분포”로

BEFORE · 무조건부 (Phase 1)

$\min_q E[\, c(q, D)\,]$

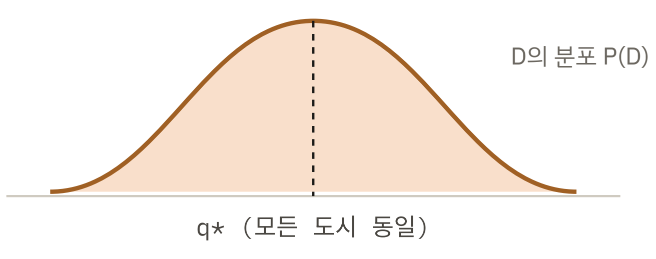

모든 도시 수요를 한 분포로 보고, 차량 수도 하나로 정합니다. 애틀랜타와 시카고가 같은 답을 받습니다.

AFTER · 조건부 = Contextual (Phase 2)

$\min_q E[\, c(q, D) \mid X = x\,] \rightarrow q\star(x)$

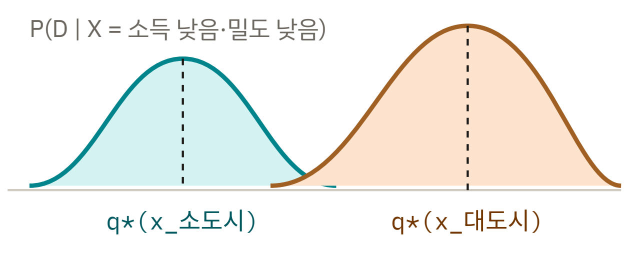

도시 특성 x를 먼저 보고, 그 도시의 **조건부 분포**에 맞춰 차량 수를 정합니다. 결정은 x의 함수 q*(x), 즉 **정책(policy)**이 됩니다.

어려운 점

P(D | X = x)는 직접 관측되지 않습니다. 우리가 가진 것은 과거 도시들의 쌍 $(x_1,D_1), \dots, (x_n,D_n)$뿐. **“이 쌍들로 새 도시 x의 조건부 분포를 어떻게 만들까”**가 C2·C3·C4 전체의 질문입니다.

C2 Sadana et al. 2024 Survey — 방법의 지도

“예측과 최적화를 얼마나 붙일 것인가”로 방법을 분류

◀ 분리 (SLO · Sequential) — 결합 (ILO · Integrated) ▶

① Estimate-then-Optimize

`X → 회귀·분포추정 → P̂(D|x)`
`→ min E_P̂[c]`

예측 모델을 먼저 만들고 그 결과를 최적화에 **꽂는다**. 가장 직관적·모듈식. 통계 전공자의 도구가 그대로 쓰임.

C3 ER-SAA가 여기

② Weighted SAA

`w_j(x) = 유사도(x, x_j)`
`min Σ_j w_j(x) c(q, D_j)`

분포를 추정하지 않고, **새 도시와 닮은 과거 도시**에 더 큰 가중치.
kNN·kernel·random forest 가중. 비모수 회귀와 동일한 발상.

Phase 2 대안

③ Decision-Focused Learning

`X → f_θ → 최적화 → q`
`→ 결정 손실로 θ 갱신`

예측 모델을 MSE가 아니라 **최종 비용**으로 학습. 최적화 문제를 미분해야 해서 어렵지만, 예측이 결정에 정렬됨.

④ Direct Policy Learning

`q = π_θ(x) 를 바로 학습`
`min Σ_j c(π_θ(x_j), D_j)`

수요를 예측하지 않고 **결정 규칙 자체**를 학습. 최적 결정이 분포보다 단순할 때 유리. 해석은 어려움.

C2의 가장 중요한 주장 · 예측 정확도 ≠ 결정 품질

	모델 A	모델 B
MSE (예측 오차)	낮음 ✓	높음
틀리는 방향	대도시에서 **과소**예측	소도시에서 과대예측
실현 비용 ($c^- \gg c^+$)	높음 — 미충족 대량	낮음 ✓

미충족 페널티 c^-가 유휴 페널티 c^+보다 훨씬 크면, “어디서 틀리는가”가 “얼마나 틀리는가”보다 중요합니다. 그래서 Phase 2 평가지표는 MSE가 아니라 **regret · 미충족량 · 실현 비용**이어야 합니다.

우리 프로젝트에서 C2가 하는 일

- **위치 잡기** — 우리 모델은 ①(ER-SAA) 또는 ②(kNN-SAA), 즉 SLO. 충전소 논문 A3도 같은 SLO 구조.
- **평가 설계** — Phase 1 vs Phase 2 비교를 예측 지표가 아닌 결정 지표로.
- **확장 아이디어** — Contextual DRO(§13): P̂(x) 주위에 x에 의존하는 모호집합. 이것이 정확히 C4.
- **연구 후보** — 다중 소스 trust를 t_h(x)로 맥락 의존화 (A1과의 접점).

C3 Kannan · Bayraksan · Luedtke — ER-SAA (Empirical Residuals SAA)

“패턴은 회귀가, 흩어짐은 잔차가 담당한다”

과거 도시가 n개뿐이면 새 도시 x의 조건부 분포를 직접 추정할 수 없습니다. ER-SAA의 해법: 수요를 **D = f(X) + ε**로 쪼개고, f는 회귀로 배우고, ε의 분포는 **잔차를 그대로 재사용**합니다.

1 회귀 적합

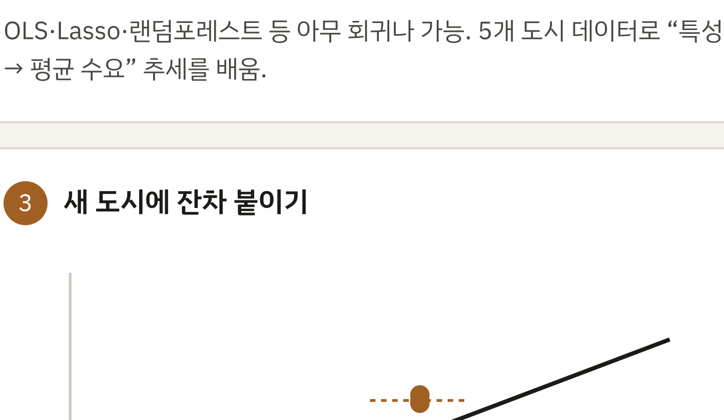

`(x_j, D_j), j=1..n → f̂ = argmin Σ (D_j − f(x_j))²`

OLS·Lasso·랜덤포레스트 등 아무 회귀나 가능. 5개 도시 데이터로 “특성 → 평균 수요” 추세를 배움.

2 잔차 모으기

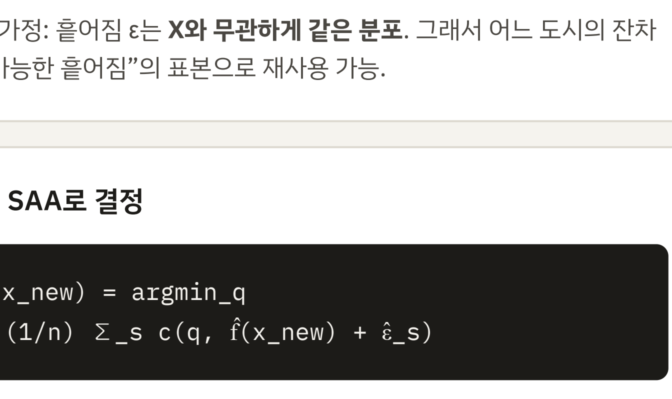

`{ε̂_1, …, ε̂_n} = 회귀선에서 벗어난 거리들`

핵심 가정: 흩어짐 ε는 **X와 무관하게 같은 분포**. 그래서 어느 도시의 잔차든 “가능한 흩어짐”의 표본으로 재사용 가능.

3 새 도시에 잔차 붙이기

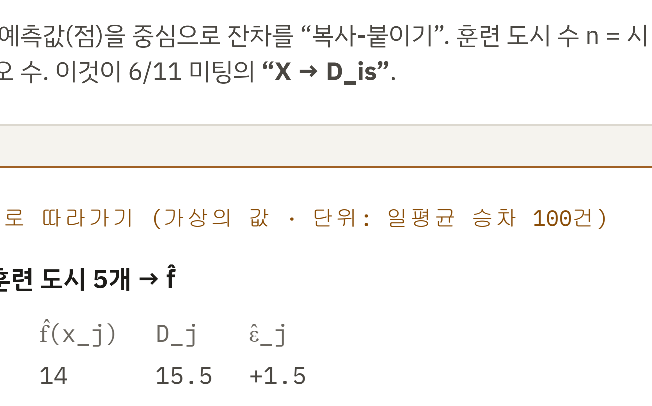

`시나리오 s=1..n: D_s(x_new) = f̂(x_new) + ε̂_s`

회귀 예측값(점)을 중심으로 잔차를 “복사-붙이기”. 훈련 도시 수 n = 시나리오 수. 이것이 6/11 미팅의 **“X → D_is”**.

4 SAA로 결정

```
q̂(x_new) = argmin_q
  (1/n) Σ_s c(q, f̂(x_new) + ε̂_s)
```

보통의 SAA와 완전히 같은 형태 — 시나리오만 x_new에 맞춰 이동됐을 뿐. 뉴스벤더면 답은 시나리오의 **$c^-/(c^++c^-)$ 분위수**.

논문의 기여: f̂이 일관 추정량이면 q̂(x)도 진짜 q*(x)로 수렴함을 증명 (일관성 + 수렴 속도).

숫자로 따라가기 (가상의 값 · 단위: 일평균 승차 100건)

① 훈련 도시 5개 → f̂

도시	f̂(x_j)	D_j	ε̂_j
SF	14	15.5	+1.5
PHX	9	8.0	−1.0
LA	18	17.2	−0.8
AUS	8	9.1	+1.1
MIA	11	10.2	−0.8

② 새 도시 ATL: f̂(x_ATL) = 10 → 시나리오 5개

`D_s = 10 + ε̂_s`
`= {11.5, 9.0, 9.2, 11.1, 9.2}`
`정렬: 9.0 · 9.2 · 9.2 · 11.1 · 11.5`

③ 뉴스벤더 결정

`c⁺=1 (유휴), c⁻=3 (유출)`
`목표 분위수 = 3/(1+3) = 0.75`
`→ q̂(x_ATL) ≈ 11.1`

Phase 1(전 도시 평균 분포)에서는 ATL도 SF와 같은 답을 받았을 것. 이제 ATL 맞춤 답이 나옵니다.

왜 좋은가 조건부 분포 전체를 추정할 필요 없이 **회귀 하나 + 잔차**로 끝. n이 작아도(도시 5–20개) 작동. kNN처럼 “닮은 도시”가 없어도 회귀가 외삽.

주의점 잔차가 X와 무관하다는 가정. 대도시 수요 변동이 더 크면(**이분산성**) D = f(X) + Q(X)·ε 로 확장 — 잔차를 도시 규모로 표준화 후 재사용. 또한 f̂ 자체가 틀리면 시나리오 전체가 편향 → C4로.

C4 Kannan · Bayraksan · Luedtke — Residuals-based DRO

“잔차 분포도 믿지 말고, 그 근처 최악까지 대비하라”

C3의 시나리오는 두 가지 이유로 틀릴 수 있습니다: (i) 잔차가 n개뿐이라 경험분포가 진짜 ε 분포와 다르고, (ii) f̂이 틀리면 중심이 통째로 어긋납니다. C4는 잔차 경험분포 주위에 **모호집합(ambiguity set)**을 두고, 그 안의 최악 분포에 대해 최적화합니다.

C3 · ER-SAA — 경험분포 P̂_n 하나만 믿음

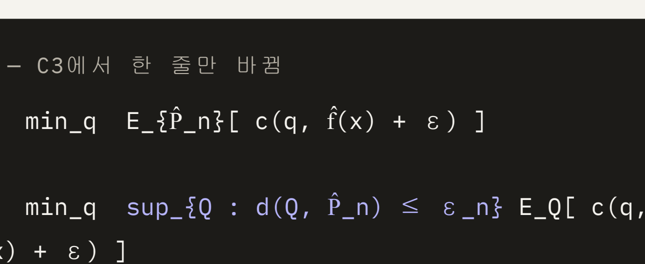

잔차 5개가 곧 “가능한 세계” 5개. 관측 안 된 큰 잔차(예: 갑작스러운 수요 폭증)는 확률 0으로 취급됨.

C4 · Residuals-DRO — P̂_n 주위 반경 ε의 공 안에서 최악

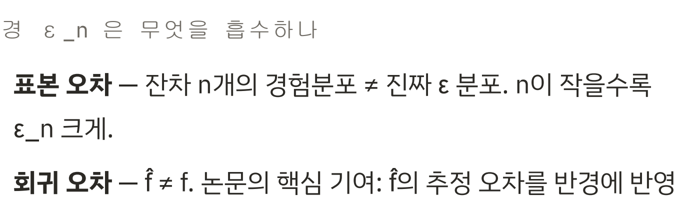

“진짜 분포는 P̂_n에서 거리 ε 안 어딘가”라고만 가정. 잔차를 조금 옮기거나(Wasserstein) 가중치를 바꾼(φ-divergence) 분포 중 **가장 비용이 큰 것**에 대비.

식 — C3에서 한 줄만 바뀜

```
C3  min_q  E_{P̂_n}[ c(q, f̂(x) + ε) ]

C4  min_q  sup_{Q : d(Q, P̂_n) ≤ ε_n} E_Q[ c(q,
f̂(x) + ε) ]
```

d = Wasserstein 거리 또는 φ-divergence. 반경 ε_n은 n이 커지면 0으로 → C4는 C3로 수렴. 두 논문의 관계가 그대로 식에 보임.

반경 ε_n 은 무엇을 흡수하나

- **표본 오차** — 잔차 n개의 경험분포 ≠ 진짜 ε 분포. n이 작을수록 ε_n 크게.
- **회귀 오차** — f̂ ≠ f. 논문의 핵심 기여: f̂의 추정 오차를 반경에 반영하는 방법과, 그래도 일관성이 유지됨을 증명.
- **이분산성** — D = f(X)+Q(X)ε 에서 Q̂도 틀릴 수 있음 → 표준화 잔차 기준으로 모호집합 구성.

Phase 3 실무: ε_n을 교차검증·bootstrap으로 보정하고 SAA vs DRO out-of-sample 비용을 비교 (B2 논리).

결정에 미치는 효과 (뉴스벤더 직관)

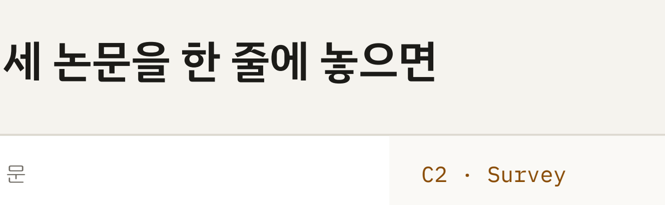

$c^- > c^+$이면 최악 분포는 수요가 큰 쪽으로 질량을 옮김 → DRO 답은 SAA보다 **차량을 더 배정**. 반경이 곧 “보수성의 양”. 대가는 평균적으로 유휴 차량 증가.

Σ 세 논문을 한 줄에 놓으면

질문	C2 · Survey	C3 · ER-SAA	C4 · Residuals-DRO
어떤 방식으로 X를 결정에 넣을까?	**지도.** 4가지 접근 · SLO/ILO · 평가는 결정 품질로	Estimate-then-optimize (SLO)	C3와 동일 + 견고화
X → 시나리오를 구체적으로 어떻게?	—	**레시피.** D_s = f̂(x) + ε̂_s, 그대로 SAA	C3와 동일
그 시나리오가 틀리면?	Contextual DRO 개념 제시	—	**보험.** 잔차 경험분포 주위 반경 ε_n 모호집합
우리 로드맵 위치	Phase 2 설계 근거 · 평가 지표	**Phase 2** 구현 방법	**Phase 3** 구현 방법

기억할 문장

C2: “예측이 좋다고 결정이 좋은 건 아니다.” · C3: “패턴은 회귀가, 흩어짐은 잔차가.” · C4: “잔차 분포도 믿지 말고 반경 안 최악에 대비.”